



جامعة حلب

كلية الهندسة المعلوماتية

قسم الذكاء الصناعي

# ترميم المخطوطات باستخدام التعلم العميق



## إعداد الطلاب:

محمود بنان

أمجد حاج حمادة

محمد ديب جلب

مهذب العبد الله

محمود عبد الرحيم

## بإشراف الدكتور:

محمد فاضل سكر

# شكر وتقدير:

الحمد لله تعالى الذي أفاض علينا من نعمته وجميل عطائه وهدانا لأن نسلك طريق العلم والمعرفة، وألهمنا ما تيسر من دراسة هذه العلوم الجليلة وأعاننا على ذلك، ننثني عليه ونحمده كما ينبغي لجلال وجهه وعظيم سلطانه. انطلاقاً من قول الله تعالى: (وَلَا تَبْخَسُوا النَّاسَ أَشْيَاءَهُمْ وَلَا تُفْسِدُوا فِي الْأَرْضِ بَعْدَ إِصْلَاحِهَا ذَلِكُمْ خَيْرٌ لَّكُمْ إِن كُنْتُمْ مُؤْمِنِينَ). [سورة الأعراف: الآية 85]

وتصديقاً بقوله – صلى الله عليه وسلم – "من لا يشكر الناس لا يشكر الله"

نتقدم بجزيل الشكر والعرفان لكل من كان له فضل علينا، ولكل من زرع فينا بسمه، أو منحنا أملاً، أو ترك في قلوبنا أثراً طيباً.

شكراً لوالدينا وإخواننا وأخواتنا، وأقاربنا وأصدقائنا وأحبابنا وزملائنا، ولأساتذتنا الكرام، وجامعتنا ووطننا العزيز، على ما قدموه لنا من دعم ومؤازرة.

كما نتوجه بخالص الشكر والتقدير إلى صاحب العلم الغزير والتواضع الجم، أستاذنا الخلق،

**الدكتور محمد فاضل سكر**

الذي لم تسعفنا الكلمات للتعبير عن عمق امتناننا له، فقد كان شجرةً وارفة الظلال، أينعت بالثمار العلمية والفكرية التي أكرمنا بها.

# الملخص:

يُعد الحفاظ على التراث المكتوب وترميم المخطوطات القديمة من أهم التحديات في عصر التحول الرقمي. إذ تحتوي هذه المخطوطات على كنوز معرفية وتاريخية قيّمة، إلا أن تقادمها وتعرضها للتلف يجعل من الصعب الاستفادة منها بشكل مباشر. لذلك، يهدف هذا المشروع إلى تطوير نظام حاسوبي يقوم بتحويل صور المخطوطات القديمة إلى نصوص رقمية قابلة للمعالجة والحفظ والبحث.

تعتمد منهجيتنا على استخدام تقنيات معالجة الصور لاستخراج النصوص من المخطوطات، ثم تطبيق خوارزميات التعرف الضوئي على الحروف (OCR) المكيفة مع طبيعة الخط العربي القديم، مع تحسينات باستخدام تقنيات الذكاء الاصطناعي والتعلم العميق لزيادة دقة التحويل. يساهم هذا المشروع في حفظ التراث الإنساني وإتاحته للباحثين والمهتمين بشكل يسهل الوصول إليه ومعالجته، مما يعزز من استدامة المعرفة التاريخية ويمنع ضياعها بمرور الزمن.

Page.jpg

كائن من المقادير إلى يوم القيامة فلا يتبدل  
ولا يتغير المكتوب عما هو عليه إلى أجل مسمى  
والأمور المقدرة في الأزل لا تتغير ولا تتبدل  
وكما يقع فهو المقدرة فيه فلا مجال للتبدل و  
لا احتمال للتحويل رواه المؤلف عن ابن عباس  
قال بعض الشراح حسن غريب إذا سألت  
فاسأل الله تعالى لأن الأمور كلها راجعة  
إليه ولا قادر ولا معطي ولا مانع ولا ضار  
ولا نافع إلا هو فهو أحق أن يقصد وإذا  
أريدت الإعانة على أمر من أمور الدنيا والآخرة  
فاسئعن بالله لا بغيره إذ لا معين سواه فلا  
اعتماد إلا عليه ولا استناد إلا إليه وهو  
الذي بيده العصمة والتأييد والنعمة والقدرة

Page.docx

كائن من المقادير إلى يوم القيامة فلا يتبدل  
ولا يتغير المكتوب عما هو عليه إلى أجل مسمى  
...  
.....  
.....

## الكلمات المفتاحية:

ترميم المخطوطات - التحويل الرقمي - التعرف الضوئي على الحروف - حفظ التراث - الأرشفة الإلكترونية

# الفهرس

|         |                                               |
|---------|-----------------------------------------------|
| 5.....  | الفصل الأول: المقدمة                          |
| 6.....  | 1- الهدف من المشروع                           |
| 7.....  | الفصل الثاني: مفاهيم عامة والتقنيات المستخدمة |
| 8.....  | Python -1-2                                   |
| 8.....  | 1-1-2 المكتبات الأساسية في المشروع            |
| 9.....  | NumPy-1-1-1-2                                 |
| 9.....  | Pandas-2-1-1-2                                |
| 10..... | TensorFlow -3-1-1-2                           |
| 10..... | Pillow -4-1-1-2                               |
| 11..... | Keras -5-1-1-2                                |
| 11..... | NLTK -6-1-1-2                                 |
| 12..... | Natural Language Processing (NLP) -7-1-1-2    |
| 12..... | Neural Networks -2-2                          |
| 12..... | 1-2-2 ما هي الشبكات العصبية                   |
| 12..... | 2-2-2 أهمية الشبكات العصبية                   |
| 12..... | 3-2-2 كيف تعمل الشبكات العصبية                |
| 13..... | 4-2-2 مكونات الشبكات العصبية                  |
| 14..... | 5-2-2 أنواع الشبكات العصبية                   |
| 14..... | 1-5-2-2 الشبكات العصبية متعددة الطبقات        |
| 14..... | 2-5-2-2 الشبكات العصبية الالتفافية            |
| 14..... | 3-5-2-2 الشبكات العصبية المتكررة              |
| 15..... | 4-5-2-2 الشبكات العصبية طويلة المدى           |

|         |                                                      |
|---------|------------------------------------------------------|
| 15..... | Transformers-3-2                                     |
| 16..... | 1-3-2- المكونات الأساسية                             |
| 16..... | 2-3-2- التطورات والآليات المتقدمة                    |
| 18..... | <b>الفصل الثالث: أساليب الصور التقليدية وتحديثها</b> |
| 19..... | 1-3- أساليب معالجة الصور التقليدية وتحديثها          |
| 20..... | 1-1-3- معالجة الصورة بتطبيق حد عتبة ثابت             |
| 21..... | 2-1-3- معالج الصورة بتطبيق حد عتبة ديناميكي          |
| 25..... | 3-1-3- معالجة الصورة بتطبيق المرشحات                 |
| 30..... | 4-1-3- معالجة الصورة بتطبيق خوارزميات اكتشاف الحواف  |
| 33..... | 2-3- تجربة مع نموذج DocEnTR                          |
| 36..... | <b>الفصل الرابع: التعلم العميق</b>                   |
| 37..... | 1-4- التعلم العميق                                   |
| 37..... | 1-1-4- الكاشف عن الكائنات                            |
| 40..... | 2-1-4- وصف الصورة                                    |
| 46..... | 1-2-1-4- MobileNet                                   |
| 48..... | 2-2-1-4- الضبط الدقيق                                |
| 48..... | 3-2-1-4- التصنيف متعدد التسميات                      |
| 54..... | 4-2-1-4- CLIP                                        |
| 55..... | 5-2-1-4- EfficientNet                                |
| 66..... | 2-4- المراجع References                              |
| 67..... | 3-4- الملخص Summary                                  |

# الفصل الأول: المقدمة

# المقدمة:

تعتبر المخطوطات العربية كنوزاً حضارية ومستودعات معرفية فريدة، فهي ليست مجرد وثائق تاريخية، بل هي شهادات حية على تطور الحضارة الإنسانية في المنطقة العربية. إلا أن هذه الكنوز تواجه تحديات جسيمة تتعلق بالحفظ والبقاء. فعوامل البيئة مثل الرطوبة وطرق التخزين أحياناً، تؤدي إلى تدهور حالتها المادية بشكل مستمر.


يُطبَّق ترميم المخطوطات على نطاق واسع في المؤسسات الثقافية، ودور الأرشيف، والمكتبات للحفاظ على الوثائق التراثية التي تتراوح تطبيقاتها من الأبحاث التاريخية إلى الدراسات اللغوية والدينية.

يُعد الحفاظ على التراث المكتوب وترميم المخطوطات القديمة من أهم التحديات في عصر التحول الرقمي. إذ تحتوي هذه المخطوطات على كنوز معرفية وتاريخية قيّمة، إلا أن تقادمها وتعرضها للتلف يجعل من الصعب الاستفادة منها بشكل مباشر. لذلك، يهدف هذا المشروع إلى تطوير نظام حاسوبي يقوم بتحويل صور المخطوطات القديمة إلى نصوص رقمية قابلة للمعالجة والحفظ والبحث.

تعتمد منهجيتنا على استخدام تقنيات معالجة الصور لاستخراج النصوص من المخطوطات، ثم تطبيق خوارزميات التعرف الضوئي على الحروف (OCR) المكيفة مع طبيعة الخط العربي القديم، مع تحسينات باستخدام تقنيات الذكاء الاصطناعي والتعلم العميق لزيادة دقة التحويل. يساهم هذا المشروع في حفظ التراث الإنساني وإتاحته للباحثين والمهتمين بشكل يسهل الوصول إليه ومعالجته، مما يعزز من استدامة المعرفة التاريخية ويمنع ضياعها بمرور الزمن.

## 1- الهدف من المشروع:

يهدف هذا المشروع إلى توظيف تقنيات التعلم العميق في بناء نظام متكامل وذكي لترميم وتحويل المخطوطات العربية القديمة المتضررة إلى مستندات إلكترونية رقمية قابلة للبحث والتعديل. سيتضمن ذلك مراحل أساسية مترابطة تبدأ بمعالجة صور المخطوطات لتحسين جودتها، ترميم الأجزاء التالفة أو المفقودة رقمياً، وإزالة التشوهات والعيوب الناتجة عن الزمن.



## الفصل الثاني:

### مفاهيم عامة والتقنيات المستخدمة



تعتبر لغة بايثون (Python) من لغات البرمجة عالية المستوى.

تتميز ببساطة تركيبها ووضوحها، مما يجعلها سهلة التعلم والقراءة. وهي تُستخدم على نطاق واسع في مجالات متعددة، منها تطوير الويب، تحليل البيانات، والأهم من ذلك، الذكاء الاصطناعي والتعلم العميق.

ما يميز بايثون بشكل خاص هو مجتمعها الضخم والنشط، والذي أنتج مجموعة هائلة من المكتبات والأطر البرمجية المتخصصة.

على سبيل المثال، تعتبر مكتبات مثل **NumPy** و **Pandas** أدوات أساسية لمعالجة وتحليل البيانات، في حين أن أطر عمل مثل **TensorFlow** و **PyTorch** تُعد العمود الفقري لتطوير وتدريب نماذج التعلم العميق.

هذه البيئة الغنية من الأدوات تجعل عملية بناء وتدريب النماذج العميقة أكثر كفاءة وسرعة، مما أدى إلى اعتمادها كلغة رئيسية لتطوير هذا المشروع.

### 2-1-1- المكتبات الأساسية في المشروع:

لإنجاز هذا المشروع، تم الاعتماد على مجموعة من المكتبات البرمجية المتخصصة، التي شكّلت البنية التحتية للتنفيذ والتجريب. ومن أبرز هذه المكتبات:

## 2-1-1-1-NumPy:



تُعد مكتبة **NumPy** (Numerical Python) من أهم المكتبات العلمية في لغة بايثون، وقد صُممت لتكون أداة أساسية في معالجة البيانات العددية.

تتميز هذه المكتبة بقدرتها على التعامل مع **المصفوفات متعددة الأبعاد (Arrays)** بكفاءة عالية، حيث توفر بدائل أكثر سرعة ومرونة من القوائم التقليدية في بايثون.

تتيح **NumPy** إجراء مجموعة واسعة من العمليات الرياضية مثل الجمع والطرح والضرب والمصفوفات، بالإضافة إلى تطبيق الدوال الإحصائية والخطية والمعقدة، وذلك بسرعة تُضاهي اللغات منخفضة المستوى مثل **Fortran** و **C**، ويعود ذلك إلى أن المكتبة مبنية داخلياً على هذه اللغات، مما يجعلها الخيار الأمثل عند التعامل مع البيانات الضخمة.

ومن مزايا **NumPy** أيضاً أنها تشكل القاعدة الأساسية للعديد من مكتبات الذكاء الاصطناعي ومعالجة البيانات، مثل **TensorFlow** و **Pandas**، حيث يعتمد عمل هذه المكتبات عليها في معالجة الأعداد والمصفوفات. وبذلك يمكن القول إن **NumPy** هي العمود الفقري للحوسبة العلمية في بايثون، ومن دونها يصبح تنفيذ كثير من الخوارزميات أكثر تعقيداً وأقل كفاءة.

## 2-1-1-2-Pandas:



مكتبة **Pandas** هي مكتبة مفتوحة المصدر في لغة بايثون تُستخدم لمعالجة البيانات وتحليلها بشكل فعال وسهل.

تتيح **Pandas** التعامل مع البيانات المهيكلة مثل الجداول بسهولة من خلال هياكل بيانات قوية.

مثل **DataFrame** و **Series**.

كما تدعم المكتبة قراءة وكتابة البيانات من مصادر مختلفة، وتنظيفها، وتحليلها إحصائياً، وفرزها وتجميعها، إضافةً إلى التعامل مع التواريخ والأوقات بطريقة مرنة.

## 2-1-1-3: TensorFlow

مكتبة **TensorFlow** هي إطار عمل مفتوح المصدر يُستخدم لبناء وتدريب نماذج التعلم العميق والذكاء الاصطناعي.



توفر TensorFlow أدوات لمعالجة البيانات، إنشاء الشبكات العصبية، حساب التدرجات، وتحسين النماذج بطريقة فعّالة وقابلة للتوسع على وحدات المعالجة المختلفة (TPU, GPU, CPU)

# TensorFlow

وهناك مكتبات تكميلية أو امتدادات لمكتبة **TensorFlow**، حيث صُممت لدعم وتسريع العمل داخل بيئة TensorFlow نفسها:

### 1- TensorFlow Hub

مكتبة **TensorFlow Hub** هي منصة لمشاركة وإعادة استخدام نماذج التعلم الآلي الجاهزة. تتيح للمطورين تحميل نماذج مُدرّبة مسبقاً وإعادة استخدامها في مشاريعهم، مثل تصنيف الصور، تحليل النصوص، أو التعرف على الكلام، مما يوفر الوقت والجهد في التدريب من الصفر.

### 2- TensorFlow Datasets

مكتبة **TensorFlow Datasets (TFDS)** توفر مجموعة كبيرة من المجموعات البياناتية الجاهزة للاستخدام في تدريب وتقييم نماذج التعلم الآلي. تدعم TFDS تحميل البيانات بسهولة بصيغ متوافقة مع TensorFlow، مع تقسيمها إلى مجموعات تدريب واختبار وتجريب، مع الحفاظ على جودة البيانات وسهولة التعامل معها.

## 2-1-1-4: Pillow

مكتبة **Pillow** هي مكتبة مفتوحة المصدر في لغة بايثون تُستخدم لمعالجة الصور والتعامل معها بسهولة.



توفر الأدوات اللازمة لفتح الصور، تعديلها، حفظها، وتطبيق العديد من العمليات مثل التغيير في الحجم، القص، التدوير، الفلترة، والتحويل بين صيغ الصور المختلفة.



# Keras

مكتبة **Keras** هي مكتبة مفتوحة المصدر في لغة بايثون تُستخدم لبناء وتدريب نماذج التعلم العميق بطريقة سهلة وسريعة. توفر Keras واجهة عالية المستوى لإنشاء الشبكات العصبية، مع دعم كامل لمكتبات التعلم العميق مثل **TensorFlow**. كما تسهل Keras تصميم النماذج، تجربة الطبقات المختلفة، وضبط المعلمات، مما يجعلها أداة مناسبة للمطورين والباحثين لإنشاء نماذج دقيقة وفعالة دون الحاجة للغوص في التفاصيل المعقدة.

تُعتبر **NLTK** أداة أساسية لأي مشروع يحتاج إلى فهم وتحليل النصوص اللغوية بشكل دقيق، وتتيح للمستخدمين العمل على النصوص بطريقة منهجية ومرنة دون الحاجة لبناء الأدوات من البداية.

مكتبة **NLTK (Natural Language Toolkit)** هي مكتبة مفتوحة المصدر في لغة بايثون متخصصة في معالجة اللغات الطبيعية وتحليل النصوص. توفر NLTK مجموعة واسعة من الأدوات للتعامل مع النصوص، بما في ذلك تحليل الكلمات، تقسيم الجمل، التنقيب عن المعلومات، تصنيف النصوص، وعمل المعاجم اللغوية. كما تشمل المكتبة مجموعات بيانات لغوية جاهزة، قواعد لغوية، ونماذج تحليلية تساعد الباحثين والمطورين على بناء تطبيقات معالجة اللغة الطبيعية مثل تحليل المشاعر، التعرف على الكيانات، الترجمة الآلية، وأنظمة المحادثة.

## 2-1-1-2: Natural Language Processing (NLP)

**معالجة اللغات الطبيعية** هي فرع حيوي من حقول الذكاء الاصطناعي، يهدف إلى تمكين الآلات من معالجة وفهم اللغة البشرية. تمنح هذه التقنية الأجهزة القدرة على أداء مهام معقدة بشكل تلقائي، مثل استخلاص المعلومات من النصوص، وفهم بنيتها، وتحويلها إلى صيغ يمكن للأنظمة الحاسوبية التعامل معها بفعالية.

إذ تُعد **معالجة اللغات الطبيعية** حجر الزاوية، حيث تُستخدم لتحويل المحتوى البصري للمخطوطات القديمة إلى نصوص رقمية قابلة للقراءة. على سبيل المثال، تُستخدم هذه التقنية في مهمة **وصف الصورة** التي تقوم بتحليل الصورة وفهم محتواها، ثم توليد نص يعبر عن هذا المحتوى بلغة سليمة. يمكن لهذا النظام أن يساعد المؤسسات الثقافية والباحثين على حفظ هذا التراث الثقافي الغني بشكل دائم، وتسهيل عملية البحث في هذه النصوص ومشاركتها، مما يضمن بقاء هذا الإرث للأجيال القادمة.

## 2-2: Neural Networks

### 2-2-1: ما هي الشبكات العصبية (What is Neural Networks)

هي أنظمة حاسوبية مستوحاة من بنية الدماغ البشري. تتكون هذه الأنظمة من مجموعة من الطبقات التي تحتوي على عقد مترابطة، حيث تقوم كل عقدة بمعالجة جزء من البيانات قبل إرسالها إلى العقد التالية. تُعد الشبكات العصبية حجر الزاوية في مجال التعلم العميق، حيث تُمكن النماذج من تعلم الأنماط المعقدة في البيانات بشكل تلقائي.

### 2-2-2: أهمية الشبكات العصبية (Importance of Neural Networks)

تكمن أهمية الشبكات العصبية في قدرتها على حل المشكلات المعقدة التي تفشل فيها الأساليب التقليدية. فهي لا تحتاج إلى برمجة صريحة لكل قاعدة أو ميزة، بل تتعلم تلقائياً من البيانات، مما يجعلها مثالية للتعامل مع البيانات غير المنظمة مثل الصور والنصوص. هذه القدرة على التعلم والتكيف سمحت لها بتحقيق إنجازات هائلة في مجالات مثل التعرف على الصور، ومعالجة اللغات الطبيعية، وأنظمة التوصية، مما جعلها حجر الزاوية في ثورة الذكاء الاصطناعي.

### 2-2-3: كيف تعمل الشبكات العصبية (How Neural Networks works)

الشبكات العصبية الاصطناعية ما هي إلا محاكاة مبسطة لعمل دماغ الإنسان، حيث تتعاون وحداتها معاً لتشكيل منظومة قادرة على التعلم من البيانات. فهي تتألف من طبقات متتابعة، تستقبل المعلومة أولاً في صورتها الخام، ثم تمررها من طبقة إلى أخرى، لتصلقها في كل مرحلة وتستخلص منها أنماطاً وخصائص أعمق. وفي النهاية، تُقدّم النتيجة في صورة قرار أو استنتاج، كالتعرف على كلمة أو صورة أو نص.

آلية التعلم في هذه الشبكات تقوم على الممارسة المستمرة، فكما يتدرب الإنسان بالتجربة والخطأ حتى يتقن مهارة ما، تتعلم الشبكة العصبية من خلال تعريضها لعدد كبير من الأمثلة، فتقارن نتائجها بما هو صحيح، وتُصحح أخطاءها تدريجياً حتى تزداد دقتها وكفاءتها.

وبفضل هذه القدرة، أصبحت الشبكات العصبية أداة أساسية في التطبيقات الحديثة، بدءًا من التعرف على الصور والأصوات، ووصولاً إلى مشاريع صون التراث، مثل تحويل المخطوطات القديمة إلى نصوص رقمية تحفظ التاريخ وتعيد إحياء المعرفة.

## 2-2-4- مكونات الشبكات العصبية (Components of neural networks):

تتكون الشبكات العصبية الاصطناعية من مجموعة عناصر مترابطة، يعمل كل منها على أداء وظيفة محددة، غير أن تآزرها معًا هو ما يمنح الشبكة قدرتها على التعلم والتعميم. ويمكن تلخيص هذه المكونات فيما يلي:

- **طبقة الإدخال:**

هي البوابة الأولى التي تستقبل البيانات الخام المراد معالجتها، مثل صورة لمخطوطة أو مقطع نصي. ويُنظر إليها باعتبارها الجسر الذي يربط العالم الخارجي بالشبكة العصبية.

- **الطبقات المخفية:**

تمثل قلب الشبكة وموضع معالجتها، حيث تمرّ البيانات عبر عقد متعددة تقوم بإجراء عمليات رياضية دقيقة، واستخلاص الخصائص العميقة والأنماط المميزة.

- **طبقة الإخراج:**

هي المحطة النهائية التي تُقدّم النتيجة المرجوة، سواء في صورة نص محوّل، أو تصنيف محدد، أو قرار نهائي تصدره الشبكة.

- **العقد العصبية (Neurons) :**

وحدات أساسية تشكّل اللبنة الصغرى للشبكة، إذ تستقبل الإشارات وتقوم بمعالجتها قبل تمريرها إلى العقد التالية.


- **الأوزان (Weights) والإزاحات (Biases) :**

تمثل الأوزان قوة الروابط بين العقد، في حين تضيف الإزاحات مرونة أكبر للشبكة، مما يساعدها على تحسين نتائجها أثناء التعلم.

- **دوال التنشيط (Activation Functions) :**

وهي القواعد التي تحدد ما إذا كانت العقدة العصبية ستسمح بمرور الإشارة أم ستوقفها، لتضفي بذلك على الشبكة القدرة على التعامل مع المشكلات المعقّدة بصورة غير خطيّة.

بهذا التكوين المتكامل، تعمل الشبكات العصبية كمنظومة ذكية قادرة على محاكاة عمليات التفكير البشري، الأمر الذي يجعلها أداة فعّالة في تطبيقات عديدة، منها تحويل المخطوطات القديمة إلى نصوص رقمية تحفظ التراث وتعيد له الحياة.



الشكل (1-2): رسمة توضيحية لبنية الشبكة العصبية

## 5-2-2- أنواع الشبكات العصبية (Kinds of Neural Networks):

### 1-5-2-2 الشبكات العصبية متعددة الطبقات (MLP – Multi-Layer Perceptron):

- تتكون من طبقة إدخال، طبقة أو أكثر مخفية، وطبقة إخراج.
- تستخدم غالبًا لحل مشاكل التصنيف والانحدار.
- كل عصبون في طبقة ما مرتبط بكل العصبونات في الطبقة التالية، وتعمل الشبكة على تعلم العلاقات غير الخطية بين البيانات.

### 2-5-2-2 الشبكات العصبية الالتفافية (CNN – Convolutional Neural Network):

- متخصصة في معالجة الصور والفيديوهات والبيانات المكانية.
- تحتوي على طبقات التفاف (Convolutional layers) لاستخراج الخصائص المهمة من الصور، وطبقات تجميع (Pooling layers) لتقليل حجم البيانات مع الحفاظ على المعلومات المهمة.
- تُستخدم في التعرف على الصور، تحليل الفيديو، ورؤية الحاسوب.

### 3-5-2-2 الشبكات العصبية المتكررة (RNN – Recurrent Neural Network):

- متخصصة في معالجة البيانات المتسلسلة مثل النصوص والسلاسل الزمنية.

- تحتوي على وصلات تعيد تمرير المعلومات بين الخطوات الزمنية، مما يسمح للشبكة بتذكر المعلومات السابقة أثناء معالجة البيانات الجديدة.
- تُستخدم في الترجمة الآلية، تحليل المشاعر، والتنبؤ بالسلاسل الزمنية.

## 2-2-5-4- الشبكات العصبية طويلة المدى (LSTM – Long Short-Term Memory):

- نوع متطور من RNN صُمم للتغلب على مشكلة اختفاء أو انفجار التدرجات في الشبكات المتكررة التقليدية.
- قادر على تذكر المعلومات الهامة لفترات زمنية طويلة والتعامل مع تسلسلات طويلة بشكل أفضل.
- تُستخدم في الترجمة، التعرف على الكلام، وتحليل النصوص الطويلة.

## 2-2-5-5- الشبكات العصبية التوليدية (GAN – Generative Adversarial Network):

- تتكون من شبكتين: مولّد (Generator) ومميّز (Discriminator) تتنافسان مع بعضهما.
- تستخدم لتوليد بيانات جديدة تشبه البيانات الحقيقية، مثل الصور والفيديوهات والنصوص.
- تُستخدم في توليد الصور الواقعية، تحسين جودة الصور، والفن الرقمي.

## 2-3-Transformers:

قبل ظهور نموذج **Transformer** في عام 2017، كانت النماذج السائدة في معالجة اللغات الطبيعية (NLP) تعتمد بشكل كبير على الشبكات العصبية المتكررة (**Recurrent Neural Networks - RNNs**) ومشتقاتها مثل **LSTM** و **GRU**. كانت هذه النماذج تعالج البيانات المتسلسلة (مثل الجملة) كلمة بكلمة، مما يسمح لها بفهم السياق. ومع ذلك، كانت تعاني من مشكلات جوهرية: أولاً، كان من الصعب جداً تدريبها على التسلسلات الطويلة بسبب مشكلة "اختفاء التدرج" (**Vanishing Gradient**)، ثانياً، كانت عملية التدريب بطيئة للغاية لأنها لا يمكن أن تتم إلا بشكل تسلسلي، مما يمنع الاستفادة من قوة الحوسبة المتوازية التي توفرها وحدات معالجة الرسومات (GPUs).

في عام 2017، أحدثت ورقة بحثية بعنوان "Attention is All You Need" (الانتباه هو كل ما تحتاجه) ثورة في هذا المجال من خلال تقديم بنية **Transformer**. الفكرة الجذرية في هذا النموذج هي التخلص الكامل من العمليات المتكررة، واعتمادها بشكل كلي على آلية جديدة تُسمى "آلية الانتباه" (**Attention Mechanism**).



### 2-3-1- المكونات الأساسية لبنية Transformer:

تتألف بنية Transformer الأساسية من جزأين رئيسيين:

- **المشفّر (Encoder):** وظيفته معالجة تسلسل المدخلات (مثل جملة) وفهم سياقها. يتكون المشفّر من عدة طبقات مترابطة، كل طبقة تحتوي على آلية انتباه ومغذيات أمامية (Feed-forward).
- **المفكك (Decoder):** وظيفته توليد تسلسل المخرجات (مثل الجملة المترجمة أو وصف الصورة). يتكون المفكك أيضاً من عدة طبقات، ولكنه يحتوي على آلية انتباه إضافية تربط بين مخرجات المشفّر ومدخلات المفكك، مما يسمح له بفهم السياق من كليهما.

### 2-3-2- آلية الانتباه (Attention Mechanism): قلب Transformer النابض

تُعد آلية الانتباه هي المفهوم الأكثر أهمية في بنية Transformer. تسمح هذه الآلية للنموذج بتقييم أهمية كل كلمة في تسلسل المدخلات بالنسبة للكلمة التي تتم معالجتها حالياً. بشكل مبسط، يمكن تخيلها كعملية حسابية تزن العلاقة بين كل كلمة والكلمات الأخرى في الجملة.

تتكون آلية الانتباه من ثلاث مصفوفات رئيسية لكل كلمة:


- **الاستعلام (Query - Q):** يمثل الكلمة الحالية التي يتم معالجتها.
- **المفاتيح (Keys - K):** تمثل جميع الكلمات الأخرى في الجملة.
- **القيم (Values - V):** تمثل معلومات محتوى كل كلمة أخرى.

تُحسب الخوارزمية مدى تشابه كل Query مع جميع Keys، وتُستخدم هذه الدرجات لتحديد الأوزان (Attention Scores). يتم بعد ذلك تطبيق هذه الأوزان على Values لتوليد مخرجات تحتوي على المعلومات الأكثر صلة. هذه العملية تسمح للنموذج بـ "التركيز" على أجزاء معينة من المدخلات، مما يمنحه فهماً سياقياً عميقاً.

### 2-3-2- التطورات والآليات المتقدمة

تعتمد بنية Transformer على عدة آليات متقدمة لتعزيز قوتها:

- **آلية الانتباه المتعددة الرؤوس (Multi-Head Attention):** بدلاً من حساب الانتباه مرة واحدة، يقوم النموذج بحسابها عدة مرات بالتوازي. كل "رأس" من هذه الرؤوس يركز على جانب مختلف من العلاقة بين الكلمات، مما يسمح للنموذج بالتقاط معلومات سياقية أكثر ثراءً.
- **التضمين الموضعي (Positional Encoding):** بما أن الـ Transformer لا يعالج الكلمات بشكل تسلسلي، فإنه يحتاج إلى طريقة لفهم ترتيب الكلمات. يتم ذلك عن طريق إضافة متجه (Vector) خاص لكل كلمة يعطي معلومات حول موقعها في الجملة.
- **التغذية الأمامية (Feed-Forward Network):** بعد كل طبقة انتباه، يتم تمرير البيانات عبر شبكة تغذية أمامية بسيطة لتوفير طبقة إضافية من المعالجة.



هذا الفصل يقدم لمحة مختصرة عن الشبكات العصبية وأنواعها الرئيسية والمحاولات ، وسيتم التعمق في شرح كل شبكة واستخداماتها العملية في الفصول القادمة، مع التركيز على الشبكات والمحاولات التي سيتم استخدامها في مشروع البحث.

## الفصل الثالث:

### أساليب معالجة الصور التقليدية وتحدياتها Traditional Image Processing Techniques and their Challenges

### 3-1- أساليب معالجة الصور التقليدية وتحدياتها:

يُعد هذا الفصل بمثابة استعراض نقدي للطرق التقليدية في معالجة الصور الرقمية، والتي كانت الخطوة الأولى في مشروعنا نحو ترميم المخطوطات القديمة. في البداية، تم اللجوء إلى هذه الأساليب كونها توفر حلاً أساسياً لمشكلات معالجة الصور، مثل إزالة التشويش، وتحسين التباين، وتحديد الحواف. وتشمل هذه الأساليب فلاتر التعقيم، وعمليات العتبة (Thresholding)، بالإضافة إلى خوارزميات كشف الحواف والأشكال الهندسية.

على الرغم من فعالية هذه الأساليب في التطبيقات العامة، إلا أنها تواجه تحديات كبيرة عند تطبيقها على المخطوطات القديمة. فالخصائص الفريدة لهذه الوثائق، مثل التلف المادي للورق، وتلاشي الحبر، والبقع، والتباين غير المنتظم في الإضاءة، تجعل الأساليب التقليدية غير كافية وغير موثوقة. فمثلاً، يمكن أن تؤدي عمليات العتبة الثابتة إلى فقدان أجزاء من النص، بينما قد تفسر خوارزميات كشف الحواف التشويش على أنه جزء من النص الأصلي.

من خلال استعراض هذه التحديات وتحليل نتائج التجارب التي أجريت على المخطوطات المتضررة، يوضح هذا الفصل لماذا كان من الضروري تجاوز هذه الأساليب والبحث عن حلول أكثر تعقيداً وذكاءً. تُعد هذه التجربة دليلاً على الحاجة الماسة إلى تقنيات متطورة تعتمد على التعلم العميق، والتي لديها القدرة على التكيف وفهم الأنماط المعقدة في البيانات، وهو ما سنستعرضه في الفصول اللاحقة.

باطوبى الشام قبل وماذا لك يا رسول الله  
قال تلك سلايكة الله عز وجل يا سطوا  
أجفنها على الشام أخبرنا عبد الرحمن  
ابن عثمان حدثنا عمي أبو بكر بن  
القاسم حدثنا أحمد بن علي القافى  
حدثنا عمرو بن الحصين حدثنا  
حدثنا معاذ بن هشام عن أبيه  
عن قتادة عن سعيد عن عبد الله بن  
المصائت عن أبي ذر عن رسول الله عنه  
قال قال رسول الله صلى الله عليه وسلم  
الشام أرض الحشر والمنشر أخبرنا أحمد


باطوبى الشام قبل وماذا لك يا رسول الله  
قال تلك سلايكة الله عز وجل يا سطوا  
أجفنها على الشام أخبرنا عبد الرحمن  
ابن عثمان حدثنا عمي أبو بكر بن  
القاسم حدثنا أحمد بن علي القافى  
حدثنا عمرو بن الحصين حدثنا  
حدثنا معاذ بن هشام عن أبيه  
عن قتادة عن سعيد عن عبد الله بن  
المصائت عن أبي ذر عن رسول الله عنه  
قال قال رسول الله صلى الله عليه وسلم  
الشام أرض الحشر والمنشر أخبرنا أحمد

باطوبى الشام قبل وماذا لك يا رسول الله  
قال تلك سلايكة الله عز وجل يا سطوا  
أجفنها على الشام أخبرنا عبد الرحمن  
ابن عثمان حدثنا عمي أبو بكر بن  
القاسم حدثنا أحمد بن علي القافى  
حدثنا عمرو بن الحصين حدثنا  
حدثنا معاذ بن هشام عن أبيه  
عن قتادة عن سعيد عن عبد الله بن  
المصائت عن أبي ذر عن رسول الله عنه  
قال قال رسول الله صلى الله عليه وسلم  
الشام أرض الحشر والمنشر أخبرنا أحمد


باطوبى الشام قبل وماذا لك يا رسول الله  
قال تلك سلايكة الله عز وجل يا سطوا  
أجفنها على الشام أخبرنا عبد الرحمن  
ابن عثمان حدثنا عمي أبو بكر بن  
القاسم حدثنا أحمد بن علي القافى  
حدثنا عمرو بن الحصين حدثنا  
حدثنا معاذ بن هشام عن أبيه  
عن قتادة عن سعيد عن عبد الله بن  
المصائت عن أبي ذر عن رسول الله عنه  
قال قال رسول الله صلى الله عليه وسلم  
الشام أرض الحشر والمنشر أخبرنا أحمد

### 3-1-1- معالجة الصورة بتطبيق حد عتبة ثابت (Static Thresholding):

تعتمد المنهجية المقترحة على معالجة صور المخطوطات. تبدأ هذه المراحل بخطوات أولية لمعالجة الصور الرقمية لتهيئتها. وقد كشفت التجارب الأولية التي تم إجراؤها باستخدام تقنيات معالجة الصور التقليدية والبسيطة، مثل تغيير الأبعاد باستخدام حيث تم إجراء تجارب باستخدام تقنيات معالجة الصور التقليدية والبسيطة، مثل تغيير الأبعاد باستخدام والتحويل إلى صور ثنائية اللون (أبيض وأسود) باستخدام عتبات ثابتة (بأحجام مختلفة مثل 50\*50، 100\*100، 1000\*1000 وعتبات مختلفة مثل 50، 100، 150).



- نلاحظ أنه بعد تحويل الصورة تم إخفاء الكلام الظاهر في الصورة الأصلية.



- نلاحظ أنه بعد تحويل الصورة تم إخفاء بعض الكلمات الظاهرة في الصورة الأصلية.

بن مالك الإيمان يمان أي يميتي فالالف  
عوض من يا النسبة وكلمة وهو العلم  
بالأشياء كما هي والعلم بها كما ينبغي يانك  
بالتحفيف المراد أهل اليمين فلما كانت  
قلوبهم معادون للإيمان وينابيح الحكمة  
نسب إليهم نسبة الشيء إلى مقدره مراد الشيا  
عن أبي هريرة الإيمان قيد الفتك أي يمنع  
من الفتك الذي هو الفتك بعد الكما  
عدو الكا يمنع القيد من التصرف وتمنه  
لايفتك مومن مراد البخاري في تاريخه  
والخطبة وغيره من الأدعية وغيره ناسخ  
جيد علم الإيمان أي مناداة الصلوة  
أي إقامة الصلوات المفروضات من

بعد تطبيق  
حد عتبة ثابت 150

بن مالك الإيمان يمان أي يميتي فالالف  
عوض من يا النسبة وكلمة وهو العلم  
بالأشياء كما هي والعلم بها كما ينبغي يانك  
بالتحفيف المراد أهل اليمين فلما كانت  
قلوبهم معادون للإيمان وينابيح الحكمة  
نسب إليهم نسبة الشيء إلى مقدره مراد الشيا  
عن أبي هريرة الإيمان قيد الفتك أي يمنع  
من الفتك الذي هو الفتك بعد الكما  
عدو الكا يمنع القيد من التصرف وتمنه  
لايفتك مومن مراد البخاري في تاريخه  
والخطبة وغيره من الأدعية وغيره ناسخ  
جيد علم الإيمان أي مناداة الصلوة  
أي إقامة الصلوات المفروضات من

- نلاحظ أنه بعد تحويل الصورة تم إظهار نتائج أفضل قليلا ولكن مازال بعض الكلمات غير واضحة كما هي ظاهرة في الصورة الأصلية.

بن مالك الإيمان يمان أي يميتي فالالف  
عوض من يا النسبة وكلمة وهو العلم  
بالأشياء كما هي والعلم بها كما ينبغي يانك  
بالتحفيف المراد أهل اليمين فلما كانت  
قلوبهم معادون للإيمان وينابيح الحكمة  
نسب إليهم نسبة الشيء إلى مقدره مراد الشيا  
عن أبي هريرة الإيمان قيد الفتك أي يمنع  
من الفتك الذي هو الفتك بعد الكما  
عدو الكا يمنع القيد من التصرف وتمنه  
لايفتك مومن مراد البخاري في تاريخه  
والخطبة وغيره من الأدعية وغيره ناسخ  
جيد علم الإيمان أي مناداة الصلوة  
أي إقامة الصلوات المفروضات من

بعد تطبيق  
حد عتبة ثابت 200


بن مالك الإيمان يمان أي يميتي فالالف  
عوض من يا النسبة وكلمة وهو العلم  
بالأشياء كما هي والعلم بها كما ينبغي يانك  
بالتحفيف المراد أهل اليمين فلما كانت  
قلوبهم معادون للإيمان وينابيح الحكمة  
نسب إليهم نسبة الشيء إلى مقدره مراد الشيا  
عن أبي هريرة الإيمان قيد الفتك أي يمنع  
من الفتك الذي هو الفتك بعد الكما  
عدو الكا يمنع القيد من التصرف وتمنه  
لايفتك مومن مراد البخاري في تاريخه  
والخطبة وغيره من الأدعية وغيره ناسخ  
جيد علم الإيمان أي مناداة الصلوة  
أي إقامة الصلوات المفروضات من

- نلاحظ أنه بعد تحويل الصورة تحسن كبير ولكن تم إظهار البقع والتشوه الظاهر في الصورة الأصلية


فقد أدت كثافة الحبر المتباينة، التلف المادي، والتنوع في الخطوط إلى ظهور تشوهات رقمية واضحة وفقدان لأجزاء من النصوص الأصلية (كلمات تم مسحها) نتيجة للكثافة غير المنتظمة للخط والحبر. أثبتت هذه التجارب أن الأساليب البسيطة ذات العتبات الثابتة غير كافية وتفشل في الحفاظ على جودة النص.

### 3-1-2- معالجة الصورة بتطبيق حد عتبة ديناميكي (Dynamic Thresholding):

بعد ملاحظة قصور طرق العتبة الثابتة في التعامل مع التباين غير المنتظم في وضوح المخطوطات، تم تطبيق حد العتبة الديناميكي كحل أكثر فعالية. تكمن الفكرة الأساسية في هذه الطريقة في معالجة كل منطقة من الصورة بشكل مستقل. ولهذا الغرض، قمنا بتقسيم الصورة إلى 25 قسماً، ثم قمنا في كل قسم بحساب متوسط وضوح البيكسل وبناءً على هذه القيمة المتوسطة لكل قسم، تم تطبيق حد عتبة ديناميكي (dynamic thresholding). سمحت لنا هذه المقاربة بمعالجة الاختلافات في الإضاءة وكثافة الحبر عبر الصورة، مما أدى إلى تحسين جودة الصورة النهائية بشكل كبير، مع الحفاظ على تفاصيل النص بشكل أفضل من الطرق السابقة.



بعد تطبيق  
حد عتبة ديناميكي



- نلاحظ أنه بعد تحويل الصورة تم اظهار شوائب أو تشويش.

أيضا أثبتت هذه التجارب أن الأساليب البسيطة ذات العتبات الديناميكية غير كافية وتفشل في الحفاظ على جودة النص.


بعد التجارب الأولية التي كشفت عن قصور طرق تحويل الصور إلى أبيض وأسود باستخدام عتبات ثابتة، قمنا باستكشاف أساليب أكثر تقدماً في معالجة الصور لعلها تتغلب على مشكلة التلف وتفاوت كثافة الحبر في المخطوطات، وكان أهمها:

### 3-1-2-1- حد عتبة أوتسو (Otsu's Binarization):

هو طريقة تلقائية لتحديد أفضل قيمة عتبة لتحويل صورة ذات تدرج رمادي إلى صورة ثنائية اللون (أبيض وأسود). على عكس الطرق اليدوية التي تتطلب منك اختيار قيمة العتبة بنفسك، يقوم خوارزمية أوتسو بتحليل توزيع درجات البكسلات الرمادية في الصورة لتحديد قيمة العتبة المثلى تلقائياً.

حيث أنه يتم تطبيق حد عتبة أوتسو وفق الصيغة الرياضية للتباين البيني هي:

$$\sigma_b^2(t) = P_0(t)P_1(t)(\mu_1(t) - \mu_0(t))^2$$



- نلاحظ أنه بعد تحويل الصورة تم اظهار أيضا بعض الشوائب أو التشويش بشكل مبالغ فيه.

ورغم أن طريقة أوتسو تُعد خياراً شائعاً وفعالاً في العديد من سيناريوهات رقمنة الوثائق، إلا أنها فشلت في تحقيق النتائج المرجوة مع مخطوطاتنا المتضررة.

### 3-2-1-2-2-1-3-2-1-3: كاشف الحواف كاني (Canny Edge Detector):

هو خوارزمية قوية ومشهورة جداً في معالجة الصور، تُستخدم لاكتشاف الحواف في الصور الرقمية. يتميز كاشف كاني بقدرته على توفير حواف دقيقة، رفيعة، ومتراصة، مما يجعله مثالياً لتحديد حدود الكائنات بشكل واضح.

تتم عملية الكشف عن الحواف باستخدام كاني عبر عدة مراحل:

**3-2-1-2-2-1-3-2-1-3: التنعيم (Gaussian Smoothing):** تبدأ الخوارزمية بتنعيم الصورة باستخدام مرشح غاوسي (Gaussian filter) لإزالة التشويش الذي قد يؤدي إلى اكتشاف حواف زائفة.

المعادلة ثنائية الأبعاد للمرشح الغاوسي هي:

$$G(x, y) = \frac{1}{2\pi\sigma^2} e^{-\frac{x^2+y^2}{2\sigma^2}}$$

**3-2-2-1-3-2-1-3-2-1-3: حساب تدرج الشدة (Intensity Gradient):** يتم حساب تدرج شدة البكسلات في كل نقطة لتحديد اتجاه وقوة الحواف المحتملة.

تُستخدم معادلات التدرج مثل عوامل تشغيل Sobel أو Prewitt لحساب التدرج الأفقي ( $G_x$ ) والرأسي ( $G_y$ ). معادلة قوة التدرج ( $G$ ) واتجاهه ( $\theta$ ) هي:


$$G = \sqrt{G_x^2 + G_y^2}$$

$$\theta = \arctan \left( \frac{G_y}{G_x} \right)$$


**3-2-2-1-3-2-1-3-2-1-3: قمع غير الحد الأقصى (Non-maximum Suppression):** تُستخدم هذه الخطوة لترقيق الحواف وضمان أن كل حافة محتملة تمثل بخط رفيع واحد، مما يزيل أي حواف سميكة أو مكررة.

**3-2-2-1-3-2-1-3-2-1-3: حدود العتبة المزدوجة والتتبع بالتوصيل (Double Thresholding and Hysteresis):**

تُطبق قيمتا عتبة (عتبة عليا وسفلى) لتصنيف الحواف.



تطبيق  
Canny Edge



- نلاحظ أنه بعد تحويل الصورة تم إعطاء نتائج غير مرضية نهائياً.

على الرغم من فاعليته في سيناريوهات أخرى، إلا أن تطبيق Canny على صور المخطوطات القديمة والمتلفة أظهر فشلاً أكبر بكثير مقارنة بطريقة OTSU. فقد نتج عن ذلك صور تحتوي على عدد مفرط من الحواف غير المرغوبة (ضوضاء).

### 3-1-3- معالجة الصورة بتطبيق المرشحات (Filters):

#### 3-1-3-1- كشف خطوط هوف للصورة (Hough Lines Detector):

هو تقنية شهيرة في مجال الرؤية الحاسوبية تُستخدم لاكتشاف الأشكال الهندسية في الصور، وتحديدًا **الخطوط المستقيمة**. الفكرة الأساسية وراءه هي تحويل المشكلة من نطاق الصورة إلى نطاق آخر يسمى "فضاء هوف" (Hough Space). في هذا الفضاء الجديد، تُصبح الخطوط المستقيمة نقاطاً، وتُصبح النقاط منحنيات.

وهناك طريقتان رئيسيتان لتمثيل وإخراج الخطوط المكتشفة بواسطة كاشف هوف، ولكل منهما طريقة عمل مختلفة:

### 3-1-3-1-1- كاشف هوف القياسي (Standard Hough Transform):

هذه هي الطريقة التي تعتمد على تحويل الخطوط إلى فضاء  $(p, \theta)$  الناتج من هذه الطريقة هو زوج من القيم لكل خط مكتشف: المسافة من نقطة الأصل  $(p)$  والزاوية  $(\theta)$ . هذه هي الطريقة الأساسية التي تحدثنا عنها سابقاً، ومعادلتها هي:

$$p = x \cos(\theta) + y \sin(\theta)$$

### 3-1-3-1-2- كاشف هوف الاحتمالي (Probabilistic Hough Transform):

هذه الطريقة هي نسخة مُحسَّنة وأكثر كفاءة من الكاشف القياسي. هي لا تكتشف الخطوط الكاملة، بل تكتشف مقاطع الخطوط (Line Segments).

هذه الطريقة تعتبر أسرع بكثير لأنها لا تقوم بتصويت كل النقاط في الصورة، بل تأخذ عينة عشوائية منها، مما يجعلها مناسبة جداً في التطبيقات التي تتطلب معالجة سريعة.


الناتج من هذه الطريقة ليس زوجاً من المسافة والزاوية، بل إحداثيات نقطتي البداية والنهاية للخط المكتشف على الشكل التالي:

$$(x_1, y_1, x_2, y_2)$$

حيث:


- $(x_1, y_1)$ : إحداثيات نقطة بداية مقطع الخط.
- $(x_2, y_2)$ : إحداثيات نقطة نهاية مقطع الخ.

بما أن هذا المرشح مصمم لكشف الخطوط المستقيمة في الصورة لذلك سنقوم بتجربتها على صور تحتوي أسطر قمنا بالتجربة وكانت النتائج:



تطبيق

Probabilistic Hough





### 3-1-3-2- مرشح قبعة المكسيكي (Mexican Hat Filter): (الحاجة إلى التنعيم المسبق)

هذا النوع المرشحات معروف بقدرته على كشف حواف الأشكال والخطوط في الصور.


يشبه مرشح قبعة المكسيكي (Mexican Hat Filter) في عمله الموجات، حيث يُستخدم للكشف عن حواف الأجسام في الصورة. يعمل هذا المرشح عن طريق البحث عن تغيرات سريعة في شدة الإضاءة، وهو ما يميز الحواف.

لكي يعمل بفعالية، يحتاج المرشح إلى صورة ناعمة (smooth) وخالية من التشويش، لأنه يتأثر بشدة بالنقاط المشتتة. لهذا السبب، يجب في العادة تطبيق فلتر تنعيم (blur) على الصورة أولاً، وقبل تطبيق هذا المرشح.

عند تطبيق مرشح قبعة المكسيكي مباشرة على صور المخطوطات الأصلية التي تحتوي على قدر كبير من التشويش والتلف، لم تُظهر الخوارزمية أي استجابة تُذكر؛ بمعنى آخر، لم تكشف عن أي حواف مفيدة أو ذات معنى. لقد بدا الأمر كما لو أن الخوارزمية "لا تفعل شيئاً" في ظل هذه الظروف المعقدة.

بيد كل واحد منهم وقع من النار يشدون قوما  
من هذه الامة يضربونهم بتلك المقامع  
ويلزمهم ااصعود فاذا صاروا الى اعلى  
احبل اسودت وجوههم ويصلبون  
على الشوك من صديد كالرماح الطوال  
من النار فيقولون يا ويلنا باي شئ نزل  
بنا هذا العذاب فيقال لهم بفرحكم في  
دار الدنيا واكتب بكم السحت وفرحكم  
بالبنيان ونشيد الاركان واتباعكم  
هوا انفسكم وفرحكم باسمه الغرور وسعكم  
علم الى الوقت المعلوم يا امير المؤمنين و...

تطبيق  
Mexican Hat




بيد كل واحد منهم وقع من النار يشدون قوما  
من هذه الامة يضربونهم بتلك المقامع  
ويلزمهم ااصعود فاذا صاروا الى اعلى  
احبل اسودت وجوههم ويصلبون  
على الشوك من صديد كالرماح الطوال  
من النار فيقولون يا ويلنا باي شئ نزل  
بنا هذا العذاب فيقال لهم بفرحكم في  
دار الدنيا واكتب بكم السحت وفرحكم  
بالبنيان ونشيد الاركان واتباعكم  
هوا انفسكم وفرحكم باسمه الغرور وسعكم  
علم الى الوقت المعلوم يا امير المؤمنين و...

- كما نرى أنه لم يتم تعديل أي شيء

يبد كل واحد منهم وقع من النار يشدون قوما  
من هذه الامة يضربونهم بتلك المقامع  
ويلزمهم الاصعود فاذا صاروا الى اهل  
الحبل اسودت وجوههم ويصلون  
على الشوك من حديد كالحراش الطوال  
من النار فيقولون يا ويلنا باي شيء نزل  
بنا هذه العذاب فيقال لهم بفرحكم في  
دار الدنيا واكنفكم السمح وفرحكم  
بالبنين ونشيد الاركان واتباعكم  
لهوا انفسكم وفرحكم بالله الغرور ووعظكم  
علم الى الوقت المعلوم يا اير المؤمنين وكم

تطبيق  
Mexican Hat




يبد كل واحد منهم وقع من النار يشدون قوما  
من هذه الامة يضربونهم بتلك المقامع  
ويلزمهم الاصعود فاذا صاروا الى اهل  
الحبل اسودت وجوههم ويصلون  
على الشوك من حديد كالحراش الطوال  
من النار فيقولون يا ويلنا باي شيء نزل  
بنا هذه العذاب فيقال لهم بفرحكم في  
دار الدنيا واكنفكم السمح وفرحكم  
بالبنين ونشيد الاركان واتباعكم  
لهوا انفسكم وفرحكم بالله الغرور ووعظكم  
علم الى الوقت المعلوم يا اير المؤمنين وكم

- تم تحديد حواف للكلمة كما أنه تم تحديد حواف البقع.

عن رسول الله صلى الله عليه وسلم عن مسروق بن  
عمارة بن جبر عن سعد بن عامر عن عبد الله بن  
عثمان بن جبر عن أبي أيوب الأنصاري قال جاء رجل الى رسول  
الله صلى الله عليه وسلم فقال عظمي وأوسر فقال إذا أخذ إلى صلاتك  
فعل صلاة مودع ولا تنكلم بكلام بعدد من عداك مع أبي أيوب  
مما في أبيه الناس رواه ابن ماجة في الزهد عن محمد بن زياد  
عن الفضل بن سليمان عن عبد الله بن عثمان بن  
عروة عنه حدثنا وكيع حدثنا حسان بن عروة عن أبيه  
عن أبي أيوب أو عن زيد بن ثابت أن النبي صلى الله عليه وسلم  
قرأ في المغرب بالاعراف في الركعتين والصلاة عن زيد بن  
مات كما تقدم والله أعلم ولكن لعروة عن أبي أيوب حديث  
فيما إذا جامع الرجل امرأته ولم ينزل من الماء من الماء وقد  
نعم في رواية زيد بن خالد عن عثمان بن عفان  
عطاء بن ربيعة عن سعد بن مسعود عن الزهري عن عطاء  
بن زيد الذي سمعت أبا أيوب محمد بن عبد الله بن عبد الله بن  
وسم قال لا تستعملوا الفلج سول ولا عائط ولكن شربا  
وعروا قال أبو أيوب قد ما التيام فوجدنا من نحن  
قد جعلت نحو القبله فيصرف واستغفر الله عز وجل رواه  
المجاوي عن علي بن الحسين ومسلم عن يحيى بن يحيى ورجو

تطبيق  
Mexican Hat



عن رسول الله صلى الله عليه وسلم عن مسروق بن  
عثمان بن جبر عن سعد بن عامر عن عبد الله بن  
عثمان بن جبر عن أبي أيوب الأنصاري قال جاء رجل الى رسول  
الله صلى الله عليه وسلم فقال عظمي وأوسر فقال إذا أخذ إلى صلاتك  
فعل صلاة مودع ولا تنكلم بكلام بعدد من عداك مع أبي أيوب  
مما في أبيه الناس رواه ابن ماجة في الزهد عن محمد بن زياد  
عن الفضل بن سليمان عن عبد الله بن عثمان بن  
عروة عنه حدثنا وكيع حدثنا حسان بن عروة عن أبيه  
عن أبي أيوب أو عن زيد بن ثابت أن النبي صلى الله عليه وسلم  
قرأ في المغرب بالاعراف في الركعتين والصلاة عن زيد بن  
مات كما تقدم والله أعلم ولكن لعروة عن أبي أيوب حديث  
فيما إذا جامع الرجل امرأته ولم ينزل من الماء من الماء وقد  
نعم في رواية زيد بن خالد عن عثمان بن عفان  
عطاء بن ربيعة عن سعد بن مسعود عن الزهري عن عطاء  
بن زيد الذي سمعت أبا أيوب محمد بن عبد الله بن عبد الله بن  
وسم قال لا تستعملوا الفلج سول ولا عائط ولكن شربا  
وعروا قال أبو أيوب قد ما التيام فوجدنا من نحن  
قد جعلت نحو القبله فيصرف واستغفر الله عز وجل رواه  
المجاوي عن علي بن الحسين ومسلم عن يحيى بن يحيى ورجو

- أيضاً نفس النتيجة تم تحديد حواف الكلمات و أيضاً تم تحديد حواف البقع.

أدركنا أن الأداء الفعال لمرشح قبعة المكسيكي يعتمد بشكل كبير على وجود صور ناعمة وخالية نسبياً من التشويش. ولذلك:

- قمنا بتطبيق فلتر تنعيم أو إزالة التشويش على الصور قبل تمريرها إلى مرشح قبعة المكسيكي، لاحظنا تحسناً كبيراً
- بعد كل هذه النتائج نوعاً ما كان مرشح قبعة المكسيكي بالفعل في رسم الحواف الخاصة بالكلمات والنصوص بوضوح أكبر.

### 3-1-4- معالجة الصورة بتطبيق خوارزميات اكتشاف الحواف (Edge detection):


تحديد مناطق النصوص (الكلمات) داخل صور تشبه المخطوطات أو الوثائق، عبر خوارزميات تقليدية، بدون استخدام نماذج تعلم عميق والخوارزميات هي:

#### 3-1-4-1- خوارزمية كاشف SIFT (Scale-Invariant Feature Transform):


هي خوارزمية قوية جداً تُستخدم في مجال الرؤية الحاسوبية لاكتشاف نقاط الاهتمام (Keypoints) في الصورة. تُعتبر هذه النقاط بمثابة "بصمات" مميزة للأجسام، حيث يمكن التعرف عليها وتحديدها في الصور حتى لو تغير حجم الجسم أو دورانه أو إضاءته.




تم استخدام خوارزمية SIFT لاكتشاف النقاط المميزة داخل النصوص.

هذه النقاط تمثل حواف وزوايا قوية غالباً ما تكون داخل الحروف.



تحديد  
Keypoints





- نتائج غير واضحة إطلاقاً حيث أن تم اكتشاف عدد كبير من النقاط في المناطق التي تحتوي على نصوص ولكن هذه النقاط لا تغطي حواف الكائن (الكلمة) بأكمله لذلك لم يتم رسم الكلمة بشكل مقبول أبداً.

- استخدمنا KMeans لتجميع النقاط من SIFT على أمل أن كل مجموعة تمثل كلمة (كلمة محاطة بمستطيل لعزل الكلمات عن بعضها). ولكن KMeans ليس مناسباً لتجميع النقاط حسب شكل الكلمات، لأنه يعتمد فقط على المسافة.

طريقة بديلة أفضل (Connected Components بعد توسعة نقاط SIFT):

قمنا بتحويل كل نقطة SIFT إلى مربع صغير.

ثم قمنا بتوسيع هذه المربعات (dilation) لدمج الحروف القريبة في كلمة واحدة.

بعد ذلك استخدمنا connectedComponents لاكتشاف كل منطقة متصلة ورسم مستطيل حولها.

النجاح:

تم رسم مستطيلات دقيقة نسبياً حول الكلمات الفعلية في الصورة.

الفشل (جزئي):

لا تزال بعض الكلمات الصغيرة أو المتقاربة جداً قد يتم دمجها أو تجاهلها حسب إعدادات dilate، لكن الطريقة تعتبر ناجحة مقارنة بما سبق.


- الطرق التقليدية تصلح لاكتشاف الكلمات بشكل مبدئي في صور واضحة، لكن دقتها محدودة، خاصة مع تشويش، بقع، أو خطوط غير متساوية.




### 3-1-4-2 خوارزمية كاشف FAST:

على عكس خوارزمية SIFT التي تُعطي أهمية كبيرة للدقة وثبات المقياس، فإن خوارزمية FAST مُصممة خصيصاً لتكون سريعة جداً في اكتشاف نقاط الاهتمام (Keypoints) في الصورة.

تعتمد خوارزمية FAST على طريقة بسيطة لكنها فعالة لاكتشاف النقاط المميزة في الصورة. الفكرة الأساسية هي البحث عن نقاط تبرز بشكل فريد عن جيرانها في محيط دائري صغير.

تقوم الخوارزمية بفحص دائرة مكونة من 16 بكسل حول نقطة إذا وجد تسلسل متصل من البكسلات (عادة 12 بكسل) أكثر سطوعاً أو أكثر عتمة بفارق عتبة محدد (يتم التحكم بها) عندها يتم اعتبار النقطة نقطة مميزة ولكنها الخوارزمية فشلت في تحديد كلمات النص.





- نتائج غير واضحة إطلاقاً حيث أن تم اكتشاف عدد كبير من النقاط في المناطق التي تحتوي على نصوص ولكن هذه النقاط لا تغطي حواف الكائن (الكلمة) بأكمله لذلك لم يتم رسم الكلمة بشكل مقبول أبداً.

لقد وجدنا، بعد بحث مطول عن كيفية توضيح الصور وإزالة الشوائب والبقع منها، نموذج ذكاء اصطناعي (شبكة عصبية) مدرب مسبقاً على هذه المهمة. هذا النموذج، الذي يُعرف باسم **DocEnTR**، مصمم خصيصاً لتوضيح وإزالة التشوهات والبقع من الصور، مما يجعله حلاً مثالياً للتعامل مع صور المخطوطات المتضررة.

### 2-3- تجربة مع نموذج **DocEnTR**:

في سياق البحث عن حلول متقدمة تتجاوز الطرق التقليدية في معالجة الصور، تم اكتشاف نموذج ذكي متخصص في ترميم الوثائق يُعرف باسم **DocEnTR**، وهو نموذج يعتمد على بنية **Transformer** ومُصمم خصيصاً لمعالجة الصور التي تحتوي على تشوهات ونصوص تالفة. بدأ هذا النموذج حلاً محتملاً لمعالجة مشكلات التلف في مخطوطاتنا.

عند تطبيق نموذج **DocEnTR** على عينة من صور المخطوطات، كانت النتائج متباينة بشكل لافت. في بعض الحالات، قدم النموذج أداءً مذهلاً، حيث قام بإزالة الخلفية وجميع الشوائب والتشوهات ومعالجة الظل الساقط على الكتابة الموجودة في الصور بشكل فعال للغاية.

## التجربة الأولى:

bijbringen, om het ook daerheen te brengen. —  
waarschijnlijk en gebuiglijk, vindt den goeverneur  
en Raden van India ook amsant de bij en de beoore  
vindt niet de beoore van gaten, pamaandhan, gaffen  
en Chaoang geijken gade, de wet gongde gepaffend  
daar versprekend, in met welch deit en amsant men —  
rooft het waden wiffen hounen noudhewen —  
geschreven int Cauteel Batavia, op t  
Eylant groot Java int Coninkrijk Sacatra Desen  
10<sup>e</sup> maart A. 1702: (onderhand) den goeverneur  
gemaet van Nederland India en geseit, Willem  
van Rithoor, den zijden hand kump: koge in  
vaden lacht geseit, en daer inden geseit, den radman  
van long geseit, daer d. (geseit) Willem de  
Roo geseit.



bijbringen, om het ook daerheen te brengen. —  
waarschijnlijk en gebuiglijk, vindt den goeverneur  
en Raden van India ook amsant de bij en de beoore  
vindt niet de beoore van gaten, pamaandhan, gaffen  
en Chaoang geijken gade, de wet gongde gepaffend  
daar versprekend, in met welch deit en amsant men —  
rooft het waden wiffen hounen noudhewen —  
geschreven int Cauteel Batavia, op t  
Eylant groot Java int Coninkrijk Sacatra Desen  
10<sup>e</sup> maart A. 1702: (onderhand) den goeverneur  
gemaet van Nederland India en geseit, Willem  
van Rithoor, den zijden hand kump: koge in  
vaden lacht geseit, en daer inden geseit, den radman  
van long geseit, daer d. (geseit) Willem de  
Roo geseit.

## التجربة الثانية:

Hi the quick brown fox jumped over  
the thing I don't remember the rest  
of this phrase or sentence but I need  
to write more words so I'm gonna  
continue writing.



Hi the quick brown fox jumped over  
the thing I don't remember the rest  
of this phrase or sentence but I need  
to write more words, so I'm gonna  
continue writing.

- صور واضحة جداً تكاد تكون مثالية للتعرف على النصوص.

مع ذلك، في حالات أخرى، كانت النتائج غير مقبولة على الإطلاق كما في الصورة التجربة التالية:

والتسليم والرضى والتبرع من المحول الحق  
الإبالة ولزوم القناعة والصبر على الصا  
في الأهل والمال وأعمالهم الصبر من عند  
الله للصبر مع الصبر لأنه سببه وهو مترتبة  
عليه فهو مع بمعنى أنه يعقده والغالب على من  
انتصر لنفسه اخذ لأن وأداء الفرج مع الكفر  
بمعنى أنه يعقده لا محالة لعدم دوامه فعليك  
أن تصبر على ما أصابك منه محتسباً راجياً وقوع  
الفرج من ذلك أن ذلك من عزم الأمور فإن  
مع الصبر الكرب وضيق الصدر ليس بالفرج  
والشرح فأخر أوقات الصبر والكرب والصبر  
أول أوقات النصر والفرج والسر فكأنها  
مقارنة لها وأعمالهم الصبر من عند



والتسليم والرضى والتبرع من المحول الحق  
الإبالة ولزوم القناعة والصبر على الصا  
في الأهل والمال وأعمالهم الصبر من عند  
الله للصبر مع الصبر لأنه سببه وهو مترتبة  
عليه فهو مع بمعنى أنه يعقده والغالب على من  
انتصر لنفسه اخذ لأن وأداء الفرج مع الكفر  
بمعنى أنه يعقده لا محالة لعدم دوامه فعليك  
أن تصبر على ما أصابك منه محتسباً راجياً وقوع  
الفرج من ذلك أن ذلك من عزم الأمور فإن  
مع الصبر الكرب وضيق الصدر ليس بالفرج  
والشرح فأخر أوقات الصبر والكرب والصبر  
أول أوقات النصر والفرج والسر فكأنها  
مقارنة لها

حيث أظهر النموذج عدم قدرة على التعامل مع أنواع معينة من التلف أو التباين في الصور، مما أدى إلى إخفاء بعض النص بدلاً من إظهارها وترميمها. نظراً لعدم استقرار النموذج وعدم إمكانية الاعتماد عليه لتقديم نتائج ثابتة وموثوقة. تم إلغاء فكرة استخدامه كجزء من المنهجية الرئيسية للمشروع، والتركيز بدلاً من ذلك على تطوير حل مخصص يمكن التحكم في أدائه بشكل كامل.

هذه النتائج أكدت مجدداً أن تحديات ترميم ورقمنة المخطوطات العربية المتضررة تتجاوز قدرة طرق معالجة الصور التقليدية، وتبرز الحاجة الملحة إلى حلول أكثر تعقيداً وذكاءً تعتمد على التعلم العميق.



الفصل الرابع:

# Deep Learning

التعلم العميق

## 4-1- التعلم العميق:

يُعدّ التعلم العميق (Deep Learning) أحد فروع التعلم الآلي (Machine Learning) .

ويُمثل نقلة نوعية في قدرة الآلات على التعلم من البيانات، تعتمد هذه التقنية على الشبكات العصبية الاصطناعية (Artificial Neural Networks) متعددة الطبقات، والمستوحاة من طريقة عمل الدماغ البشري. على عكس الطرق التقليدية التي تتطلب تحديد خصائص معينة (مثل حواف الخطوط أو كثافة الحبر) يدوياً، فإن التعلم العميق يمتلك القدرة على التعلم التلقائي لهذه الخصائص المعقدة والمجردة مباشرةً من كميات هائلة من البيانات. هذا ما يجعله الأداة المثالية للتعامل مع التحديات التي أظهرتها المخطوطات القديمة، فهو قادر على فهم الأنماط المعقدة في الصور النافقة، وإزالة التشويش، والتعرف على النصوص حتى في ظل التباين الشديد، مما يوفر حلاً قوياً وذكياً يتجاوز قدرة الأساليب التقليدية.

استناداً إلى هذه القدرات الفائقة، أصبح التعلم العميق هو الحجر الأساس في مشروعنا، حيث أتاح لنا استكشاف حلول متقدمة لم تكن ممكنة بالطرق التقليدية. كان أمامنا خياران رئيسيان لتطوير نظامنا:

- 1- الكشف عن الكائنات (Object Detection): لتحديد موقع كل كلمة أو حرف في الصورة.
- 2- وصف الصور (Image Captioning): لإنشاء وصف نصي كامل لمحتوى المخطوط.

### 4-1-1- الكشف عن الكائنات (Object Detection):

يُعد الكشف عن الكائنات (Object Detection) أحد أبرز مهام الرؤية الحاسوبية، ويُعرّف بأنه عملية تحديد وتوطين الأجسام المختلفة داخل الصورة. يتم ذلك من خلال رسم صناديق إحاطة (Bounding Boxes) حول كل كائن المكتشف، مع تقدير فئة هذا الكائن (مثال: "سيارة"، "وجه"). في سياق معالجة النصوص، يتم تطبيق هذه التقنية لاكتشاف وتوطين كل كلمة أو حرف ككائن منفصل في الصورة.

تتمثل آلية عمل الكشف عن الكائنات في تحليل الصورة وتحديد المناطق التي يحتمل أن تحتوي على كائنات. بعد تحديد هذه المناطق، يتم تمريرها عادةً عبر شبكة عصبية تقوم بتصنيف الكائن الموجود في كل منطقة ورسم صندوق إحاطة دقيق حوله. الهدف هو فهم مكان وجود العناصر المرئية وماهيتها بدقة عالية. تُستخدم هذه الطريقة بشكل فعال في تطبيقات تتطلب تحديد أجسام متباعدة وذات حدود واضحة، مثل تحديد لوحات السيارات أو التعرف على الوجوه.

توجد عدة طرق ومنهجيات في عملية الكشف عن الكائنات (Object Detection) ، ومن بينها طريقة الـ Contour التي تعتمد على تحديد الحدود الخارجية للأجسام في الصورة.

#### 4-1-1-1- الخطوط المحيطة (Contour):

تعتمد الفكرة على اكتشاف الحدود الخارجية للأجزاء المتصلة في الصورة.

يُعد الـ **(Contour الخطوط المحيطة)** أحد الأساليب المتبعة في عملية الكشف عن الكائنات. وتتمثل فكرتها في اكتشاف وتتبع الحدود الخارجية للأجسام المتصلة في الصورة، مما يساعد على تحديد شكل وموقع هذه الأجسام. في سياق معالجة النصوص، يتم تطبيق هذه الطريقة على صورة ثنائية اللون لتحديد الحدود الخارجية لكل جزء منفصل من النص (كأجزاء الحروف). وبمجرد اكتشاف هذه الخطوط المحيطة، يمكن التعامل معها ككائن مستقل. من خلال تحليل خصائص هذه الخطوط، مثل مساحتها أو شكلها، يمكن استخلاص معلومات حول الكائن الذي تمثله، مما يجعلها خطوة أساسية في عملية الكشف عن الكلمات.

تبدأ العملية بتحويل الصورة إلى صيغة ثنائية اللون (أبيض وأسود) ليتمكن النظام من التمييز بين النص والخلفية. بعد ذلك، تقوم الخوارزمية باكتشاف **الخطوط المحيطة (Contours)**، والتي تمثل الحدود الخارجية لكل جزء منفصل من النص (مثل أجزاء الحروف، أو حتى الحروف الكاملة). الخطوة التالية والأكثر أهمية هي دمج هذه الأجزاء القريبة من بعضها. يتم ذلك عن طريق تحليل المسافات بين الخطوط المحيطة المكتشفة، فإذا كانت قريبة بما يكفي من بعضها البعض، يتم دمجها معاً لتشكيل كياناً واحداً يُعتبر كلمة. هذه الطريقة تسمح بتجميع الأجزاء المبعثرة للحروف العربية المتصلة وتجميعها في كلمات كاملة.

السَّعَادَةُ فِي سَنَابِ الشَّهَادَةِ • كَشَفَ لَغَمِي فِي فَضْلِ الْحَمْدِ • الْإِقَادَةُ



السَّعَادَةُ فِي سَنَابِ الشَّهَادَةِ • كَشَفَ لَغَمِي فِي فَضْلِ الْحَمْدِ • الْإِقَادَةُ

الْمُهْجُ النَّبَوِيُّ وَالْمُهْجُ الْمَرْوِيُّ عَلَى الطَّبِيبِ النَّبَوِيِّ • الْهَيْئَةُ




الْمُهْجُ النَّبَوِيُّ وَالْمُهْجُ الْمَرْوِيُّ عَلَى الطَّبِيبِ النَّبَوِيِّ • الْهَيْئَةُ

و على الرغم من فعالية طريقة الـ **Contour** في تحديد أجزاء الكلمات، إلا أنها لم تكن الخيار الأمثل لمشروعنا، وذلك بسبب قصورها في التعامل مع تعقيدات النصوص العربية القديمة. فقد لاحظنا أنها في بعض الحالات تقوم أحياناً بدمج نهاية كلمة مع بداية كلمة أخرى بسبب تقاربها الشديد، مما يؤدي إلى تداخل غير مرغوب فيه. كما أنها تفشل في التعامل مع الحالات التي تكون فيها كلمة تحتضن كلمة أخرى، مما يجعل تحديد الكلمات بشكل منفصل أمراً صعباً ويؤثر سلباً على دقة النتائج.

مع ذلك، تبين أن هذا الخيار كان غير مناسب بشكل قاطع لمشروعنا المتعلق بترميم ورقمنة المخطوطات العربية، وذلك للعديد من الأسباب الجوهرية التي تتعلق بالخصائص الفريدة لهذه الوثائق. أولاً، تتميز الخطوط العربية القديمة في المخطوطات بأنها غالباً ما تكون متلاصقة ببعضها ويصعب فصلها بصرياً. علاوة على ذلك، تواجهنا ظاهرة تداخل الكلمات، حيث تكون بعض الكلمات تحتضن كلمات أخرى أو تتداخل معها بشكل عضوي، كما في الأمثلة الشائعة التي يمكن أن تظهر فيها أجزاء من كلمة ممتدة فوق أو تحت كلمة مجاورة (مثال توضيحي: "الحمل الذي سى" حيث تتداخل امتدادات الحروف). هذا التداخل يجعل من المستحيل عملياً رسم صناديق إحاطة دقيقة ومنفصلة لكل كلمة.


ثانياً، تصنيف البقع والتشوهات والتلف المادي الموجودة على صور المخطوطات طبقة أخرى من التعقيد. فغالباً ما تحيط هذه التشوهات بالكلمات وتتداخل مع حدودها، مما يربك خوارزميات الكشف عن الكائنات ويجعلها غير قادرة على التمييز بين النص الفعلي والضوضاء البصرية. هذه التحديات مجتمعة جعلت من استخدام منهجية الكشف عن الكائنات غير عملي وغير موثوق به لغرض استخلاص النصوص من مخطوطاتنا المتضررة.



وبالعاكس قال واغذهم بلحم المعز



سفوف يسهل المكان



المتقاطعون المتدبرون

لذلك، لجأنا إلى الخيار النهائي والوحيد الذي بدا قادراً على التغلب على هذه التحديات وهو وصف الصور (Image Captioning)، وهي تقنية تسمح للنموذج بتوليد وصف نصي كامل للصورة، مما يزيل الحاجة إلى تحديد كل كلمة على حدة. في هذا السياق.

### ثانياً: وصف الصور (Image Captioning):

**وصف الصور (Image Captioning)** باستخدام الشبكات العصبية هو عملية توليد وصف نصي تلقائي ودقيق لمحتوى الصورة. بدلاً من مجرد تصنيف الصورة (كأن نقول "هذه صورة مخطوطة")، يهدف هذا النهج إلى فهم العناصر البصرية داخلها وإنشاء جملة أو فقرة تصفها.

لتحقيق ذلك، يجب علينا تدريب شبكة عصبية على فهم العلاقة المعقدة بين الصور والنصوص. وهذا التدريب، كما ذكرت، يتطلب مجموعة بيانات (Dataset) ضخمة ومتناسقة. يجب أن تحتوي هذه البيانات على آلاف الأمثلة من الصور، حيث تكون كل صورة مقترنة بوصف نصي دقيق يصف محتواها، ليتمكن النموذج من التعلم كيف يربط بين ما يراه وما يجب أن يكتبه.

هذا يعني أننا بحاجة إلى تحضير وتجهيز مجموعة البيانات (Dataset) الخاصة بنا، بحيث تكون متوافقة مع متطلبات النماذج التي سنقوم بتدريبها.

### ❖ تجهيز الـ Dataset:

في البداية، قمنا بإجراء بحث شامل للعثور على مجموعة بيانات (Dataset) مخصصة للمخطوطات العربية القديمة. كان هدفنا هو إيجاد مجموعة جاهزة تحتوي على صور لمخطوطات فعلية مع النصوص المقابلة لها.

ولكن، لسوء الحظ، لم تكن جهودنا مثمرة. فكل ما تم إيجاده كان عبارة عن مجموعات بيانات لا تلبي متطلباتنا، مثل صور لكتابة طفل صغير، أو صور لأحرف فردية مكتوبة باليد. هذه المجموعات لم تكن مناسبة أبداً لمشروعنا الذي يتطلب نصوصاً متصلة وتحاكي تعقيد المخطوطات.

لم يتبق أمامنا سوى حل وحيد وهو تجهيز مجموعة بيانات يدوياً (Manual Dataset Preparation). كان هدفنا هو جمع ما يقارب 20,000 صورة لأسطر من المخطوطات، وليس لصفحات كاملة، وذلك لأن صور الصفحات تكون ذات حجم أكبر وتستهلك حيزاً كبيراً من الذاكرة، مما قد يؤدي إلى إبطاء عملية التدريب بشكل ملحوظ (ذاكرة VRAM في Colab لم تكفي).

لكن للأسف، تبين لاحقاً أن هذا الحجم من البيانات لم يكن كافياً لتدريب نموذج قادر على التعامل مع تعقيدات الخط العربي القديم. لذلك، اضطررنا إلى اتخاذ خطوة أخرى مبتكرة، وهي توليد مجموعة بيانات اصطناعية باستخدام كود برمجي، مع استخدام خطوط تحاكي الخط البشري في المخطوطات القديمة، مما سمح لنا بتوفير كمية أكبر من البيانات الضرورية لتدريب النموذج بشكل فعال.

حيث أصبحت كل صورة تحتوي على سطر واحد فقط من النص وكانت أبعاد الصور 70x80.

تحاكي هذه البيانات واقع المخطوطات القديمة بشكل كبير. سيتم استخدامها لتدريب النموذج على التعامل مع التحديات الحقيقية مثل البقع، التلاشي، والتلف، مما يضمن أداءً قوياً للنموذج في ظروف العالم الواقعي.

الحمد لله الواجد القهار العزيز الغفار وعلواته على محمد عبد وبييه المختار وعلى آله الطيبين

قال ينبغي أن تكون عالماً بالمعيب الذي يأتي إلى كل واحد من الأعداء وما معها عيب الجسد وما معها

بطل نفسه ولا عسر أيها وزلك واجب لأن ما كان من البتة واسترخت رجلاه ولم تنل يديه آفة ولا

وبعد جمع ودمج البيانات مع بعضها، قمنا بعملية معالجة للصور (Image Preprocessing) لتعزيز قدرة النموذج على التعلم من البيانات. كانت الخطوة الأبرز في هذه المرحلة هي تطبيق تقنية توسيع البيانات (Data Augmentation)، والتي تُعد ضرورية لزيادة كمية البيانات المتوفرة للتدريب وتحسين قدرة النموذج على التكيف مع التغيرات المحتملة في صور المخطوطات. كانت العمليات المطبقة على الصور كالتالي:

### 1- دوران Rotation:

```
tf.keras.layers.RandomRotation(0.008)
```

القيمة 0.008 أي أقصى دوران حوالي  $\pm 0.8\%$  من نصف دورة (أي تقريباً  $\pm 0.46^\circ$ ).

### 2- تقريب Zoom:

```
tf.keras.layers.RandomZoom(0.1)
```

النسبة 0.1 أي تكبير أو تصغير بنسبة تصل إلى  $\pm 10\%$ .

### 3- تغيير ارتفاع Height:

```
tf.keras.layers.RandomHeight(0.2)
```

النسبة 0.2 أي ممكن تقطع أو تمدد الصورة رأسياً لغاية  $20\%$ .

#### 4- تغيير عرض Width:

```
tf.keras.layers.RandomWidth(0.2)
```

النسبة 0.2 أي ممكن تقطع أو تمدد الصورة أفقياً بنسبة 20%.

#### 5- تغيير ارتفاع Height:

```
tf.keras.layers.RandomHeight(0.2)
```

النسبة 0.2 أي ممكن تقطع أو تمدد الصورة رأسياً لغاية 20%.

#### 6- التحويلات اللونية Color Augmentations:

```
# Stronger saturation change (50% to 150%)
image = tf.image.random_saturation(image, lower=0.5, upper=1.5)

# More hue distortion ( $\pm 20\%$ )
image = tf.image.random_hue(image, max_delta=0.2)

# Stronger brightness ( $\pm 50\%$ )
image = tf.image.random_brightness(image, max_delta=0.5)

# Larger channel shift ( $\pm 50/255 \sim \pm 0.2$ )
shift = tf.random.uniform([], -50.0 / 255.0, 50.0 / 255.0)
image = image + shift

# Clip to [0, 1]
image = tf.clip_by_value(image, 0.0, 1.0)
```

تغيير التشبع، hue، السطوع، وانحراف في الألوان.

والنتيجة بعد كل هذه العمليات كانت كالتالي:




وهنا، بعد أن أتمنا تجهيز مجموعة البيانات، ننتقل الآن إلى المرحلة التالية والمهمة (تدريب النماذج).




الشكل (4-1): توضيح لآلية عمل لنموذج Image Captioning

• آلية عمل الـ Image Captioning :



الشكل (2-4): آلية عمل Image Captioning

• بنية النموذج:



الشكل (3-4): رسمة توضيحية لبنية النموذج

كما يتضح من بنية النموذج، فإن هيكله يتكون من الشبكات العصبية CNN و Transformer نبدأ أولاً بمرحلة معالجة الصور التي تعتمد على الشبكات العصبية الالتفافية (CNN).

#### A. الشبكات العصبية الالتفافية (CNN) :

تُعد شبكات CNN من أهم أنواع الشبكات العصبية في مجال الرؤية الحاسوبية. تتميز بقدرتها الفريدة على استخلاص الخصائص البصرية من الصور بشكل تلقائي، مثل الحواف والأنماط، من خلال مجموعة من الطبقات الالتفافية (Convolutional Layers) وطبقات التجميع (Pooling Layers). هذه القدرة تجعلها الخيار الأمثل للتعامل مع صور المخطوطات المعقدة، حيث تُمكن النموذج من فهم المحتوى المرئي دون الحاجة إلى تحديد الخصائص يدوياً، على عكس الطرق التقليدية التي فشلت في ذلك.

#### 1. MobileNet :

بدأنا بتجربة نموذج MobileNet كأول خيار لنا. تم تقديم هذا النموذج من قبل باحثين من شركة جوجل في عام 2017، ويُعرف بأنه نموذج خفيف الوزن وفعال، مصمم خصيصاً للعمل على الأجهزة ذات الموارد المحدودة، وذلك بفضل بنيته المبتكرة التي تعتمد على الالتفافات القابلة للفصل. تم استخدام MobileNet كنقطة انطلاق لتقييم مدى فعالية نماذج CNN في مهمتنا، وعليه، بدأنا في تدريب النموذج على مجموعة البيانات الخاصة بنا.

حيث كانت بنية الشبكة كالتالي:

| Type / Stride                 | Kernel Size                      | Input Size ( $W \times H \times C$ ) | Output Size ( $W \times H \times C$ ) |
|-------------------------------|----------------------------------|--------------------------------------|---------------------------------------|
| Conv / s2                     | $3 \times 3 \times 3$            | $224 \times 224 \times 3$            | $112 \times 112 \times 32$            |
| Depthwise Separable Conv      | $3 \times 3$ dw, $1 \times 1$ pw | $112 \times 112 \times 32$           | $112 \times 112 \times 64$            |
| Depthwise Separable Conv / s2 | $3 \times 3$ dw, $1 \times 1$ pw | $112 \times 112 \times 64$           | $56 \times 56 \times 128$             |
| Depthwise Separable Conv      | $3 \times 3$ dw, $1 \times 1$ pw | $56 \times 56 \times 128$            | $56 \times 56 \times 128$             |
| Depthwise Separable Conv / s2 | $3 \times 3$ dw, $1 \times 1$ pw | $56 \times 56 \times 128$            | $28 \times 28 \times 256$             |
| Depthwise Separable Conv      | $3 \times 3$ dw, $1 \times 1$ pw | $28 \times 28 \times 256$            | $28 \times 28 \times 256$             |
| Depthwise Separable Conv / s2 | $3 \times 3$ dw, $1 \times 1$ pw | $28 \times 28 \times 256$            | $14 \times 14 \times 512$             |
| Depthwise Separable Conv (x5) | $3 \times 3$ dw, $1 \times 1$ pw | $14 \times 14 \times 512$            | $14 \times 14 \times 512$             |
| Depthwise Separable Conv / s2 | $3 \times 3$ dw, $1 \times 1$ pw | $14 \times 14 \times 512$            | $7 \times 7 \times 1024$              |
| Depthwise Separable Conv      | $3 \times 3$ dw, $1 \times 1$ pw | $7 \times 7 \times 1024$             | $7 \times 7 \times 1024$              |
| Global Avg Pooling            | $7 \times 7$                     | $7 \times 7 \times 1024$             | $1 \times 1 \times 1024$              |
| Fully Connected               | $1 \times 1 \times 1024$         | $1 \times 1 \times 1024$             | $1 \times 1 \times 1000$              |
| Softmax                       |                                  | $1 \times 1 \times 1000$             | $1 \times 1 \times 1000$              |

لكن أثناء التدريب، واجهتنا عدة عقبات رئيسية. أولاً، تبين أن شبكة **MobileNet** غير مصممة أو مدربة مسبقاً على التعرف على الكلمات، بل هي مخصصة لتصنيف الأجسام العامة في صور بحجم ثابت.

ثانياً، كانت هناك مشكلة جوهرية في **حجم الصور**؛ فبينما تتطلب بنية النموذج صوراً مربعة بحجم **224x224x3**، كانت صور الأسطر التي لدينا ذات أبعاد مختلفة تماماً (**70x800x3**).

كمحاولة لحل هذه المشكلة وتكييف بياناتنا مع النموذج، حاولنا في البداية عمل **resize** للصور، لكن هذه العملية أدت إلى تشويه ملامح النصوص بشكل كامل وضغطها بطريقة غير مقبولة. ثم حاولنا بوضع **padding** من الأعلى والأسفل لتصبح مربعة قبل تصغير الحجم، إلا أن هذه المحاولة أيضاً أدت إلى تغيير غير مرغوب فيه في ملامح النص الأصلي. لذلك، اضطررنا إلى عمل **ضبط دقيق (Fine-Tuning)** للنموذج.


### • الضبط الدقيق (Fine-Tuning):

**الضبط الدقيق (Fine-Tuning)** هو عملية إعادة تدريب نموذج ذكاء اصطناعي مُدرَّب مسبقاً على مهمة جديدة أو مجموعة بيانات مختلفة قليلاً. بدلاً من تدريب النموذج من الصفر، والتي قد تستغرق وقتاً طويلاً جداً وتتطلب موارد هائلة، يتم استخدام نموذج موجود كنقطة انطلاق.

في هذه العملية، يتم تحديث أوزان النموذج المدرب مسبقاً باستخدام مجموعة البيانات الجديدة. يسمح ذلك للنموذج بتعلم الخصائص الفريدة للبيانات الجديدة (في حالتنا، الأسطر العربية في المخطوطات)، مع الاستفادة من المعرفة التي اكتسبها بالفعل من تدريبه الأصلي على ملايين الصور. هذه الطريقة تُعد أكثر كفاءة وفعالية، حيث تُسرّع عملية التدريب ويُحسن من أداء النموذج على المهمة المحددة لمشروعنا.

في ذلك الوقت لم نستخدم مجموعة البيانات التي قمنا بتجهيزها يدوياً، لأنها لم تكن قد اكتملت بعد وبالتالي استخدمنا مجموعة البيانات الاصطناعية. لذلك، لكي نقوم بعمل **الضبط الدقيق (Fine-Tuning)**، لجأنا إلى أسلوبين مختلفين.

### الأسلوب الأول: التصنيف متعدد التسميات (Multi-Label Classification):



**التصنيف متعدد التسميات (Multi-Label Classification)** هو أسلوب في التعلم الآلي يتيح للنموذج توقع أكثر من فئة (class) واحدة للمدخلات. على عكس التصنيف التقليدي الذي يختار فئة واحدة فقط، فإن هذا الأسلوب يمكن أن يربط صورة ما بالعديد من الفئات في نفس الوقت.

في هذا الأسلوب، يتم تمثيل كل كلمة كفئة منفصلة، ويقوم النموذج بتنشيط عصبون واحد (neuron) في طبقة الخرج (Output Layer) لكل كلمة موجودة في الصورة. وتستخدم دالة Softmax في هذه الطبقة لضمان أن مجموع احتمالات الفئات يساوي واحد، مما يسمح للنموذج بتوقع مجموعة الكلمات الموجودة في الصورة بشكل متزامن.

في الضبط الدقيق (Fine-Tuning)، قمنا باستخدام بنية النموذج الأصلية، ولكن بدلاً من استخدام الأوزان التي تم تدريبها مسبقاً، قمنا بتهيئتها بأوزان عشوائية (Random Weights)، حيث قمنا بوضع فوق طبقات الـ CNN طبقة Flatten بعدها طبقة Dense مكونة من 512 عصبون ثم بالطبقة الأخيرة (Output Layer) مكونة من 50,000 عصبون.

🚀 قمنا بعمل Augmentation على الصور قبل إدخالها على الشبكة (كما ذكرنا في فقرة تجهيز الـ Dataset) حيث كانت Epoch = 60, batch\_size = 32, learning\_rate = 1e-4

```
model.compile(optimizer=tf.keras.optimizers.Adam(learning_rate=1e-4),
              loss=masked_loss,
              metrics=[masked_acc])
```

🚀 قمنا بعدها بتدريب الشبكة

```
history = model.fit(train_ds, validation_data=test_ds, epochs=60, steps_per_epoch=steps_per_epoch,
                    validation_steps=validation_steps, callbacks=callbacks)
```


```

100%|██████████| 32/32 [00:00<00:00, 2136.17it/s]
Epoch 1/60 | 250/250 | 0s 2s/step - train_acc: 0.7952 - val_acc: 0.7912
100%|██████████| 32/32 [00:00<00:00, 2464.97it/s]
Epoch 2/60 | 250/250 | 0s 2s/step - train_acc: 0.8074 - val_acc: 0.8032
100%|██████████| 32/32 [00:00<00:00, 2842.63it/s]
Epoch 3/60 | 250/250 | 0s 2s/step - train_acc: 0.8536 - val_acc: 0.8492
100%|██████████| 32/32 [00:00<00:00, 2315.70it/s]
Epoch 4/60 | 250/250 | 0s 2s/step - train_acc: 0.86 - val_acc: 0.856
100%|██████████| 32/32 [00:00<00:00, 2694.43it/s]
Epoch 5/60 | 250/250 | 0s 2s/step - train_acc: 0.868 - val_acc: 0.8632
100%|██████████| 32/32 [00:00<00:00, 2644.32it/s]
Epoch 6/60 | 250/250 | 0s 2s/step - train_acc: 0.876 - val_acc: 0.8704
100%|██████████| 32/32 [00:00<00:00, 2604.60it/s]

Epoch 55/60 | 250/250 | 0s 2s/step - train_acc: 0.8936 - val_acc: 0.8912
100%|██████████| 32/32 [00:00<00:00, 3382.93it/s]
Epoch 56/60 | 250/250 | 0s 2s/step - train_acc: 0.91 - val_acc: 0.91
100%|██████████| 32/32 [00:00<00:00, 3398.78it/s]
Epoch 57/60 | 250/250 | 0s 2s/step - train_acc: 0.9299 - val_acc: 0.9299
100%|██████████| 32/32 [00:00<00:00, 2580.96it/s]
Epoch 58/60 | 250/250 | 0s 2s/step - train_acc: 0.9574 - val_acc: 0.9574
100%|██████████| 32/32 [00:00<00:00, 2692.76it/s]
Epoch 59/60 | 250/250 | 0s 2s/step - train_acc: 0.9712 - val_acc: 0.9712
100%|██████████| 32/32 [00:00<00:00, 2279.75it/s]
Epoch 60/60 | 250/250 | 0s 2s/step - train_acc: 0.9985 - val_acc: 0.9815
100%|██████████| 32/32 [00:00<00:00, 3532.32it/s]

```

## النتائج:



Train\_acc = 0.9985 , val\_acc = 0.9815

وبعد الانتهاء من عملية التدريب، قمنا بحفظ معلمات النموذج (parameters) لضمان إمكانية استخدامه لاحقاً في مرحلة الاختبار والتطبيق.

تعليمية الحفظ :save

```
effnet = model.get_layer("functional_8")
effnet_model = Model(inputs=effnet.input, outputs=effnet.output)
effnet_model.save("drive/MyDrive/text_feature_extractor_v4.keras")
```

بعدها قمنا بوضع معلمات النموذج (parameters) التي حفظناها مكان معلمات النموذج المدرب مسبقاً ومنها بدأنا بعملية التدريب النموذج Image Captioning وقمنا بتجميد النموذج.

تعليمية التحميل :load

```
mobilenet = load_model("drive/MyDrive/text_feature_extractor_v4.keras")
mobilenet.trainable = False
```


```
mobilenet = load_model("drive/MyDrive/text_feature_extractor_v4.keras") لم  
mobilenet.trainable = True
```

حيث كانت Epoch = 60, batch\_size = 32, learning\_rate = 1e-4

```
Epoch 0/60 | 250/250 | 0s 2s/step - train_acc: 0.7523 - val_acc: 0.62445  
100%|██████████| 32/32 [00:00<00:00, 3119.67it/s]  
Epoch 1/60 | 250/250 | 0s 2s/step - train_acc: 0.7625 - val_acc: 0.6335  
100%|██████████| 32/32 [00:00<00:00, 3577.71it/s]  
Epoch 2/60 | 250/250 | 0s 2s/step - train_acc: 0.7733 - val_acc: 0.6414  
100%|██████████| 32/32 [00:00<00:00, 3861.49it/s]  
Epoch 3/60 | 250/250 | 0s 2s/step - train_acc: 0.7984 - val_acc: 0.6523  
100%|██████████| 32/32 [00:00<00:00, 3496.62it/s]  
Epoch 4/60 | 250/250 | 0s 2s/step - train_acc: 0.8035 - val_acc: 0.6685  
100%|██████████| 32/32 [00:00<00:00, 3320.08it/s]  
Epoch 5/60 | 250/250 | 0s 2s/step - train_acc: 0.8174 - val_acc: 0.67  
100%|██████████| 32/32 [00:00<00:00, 4004.95it/s]  
Epoch 6/60 | 250/250 | 0s 2s/step - train_acc: 0.8296 - val_acc: 0.6844  
100%|██████████| 32/32 [00:00<00:00, 3661.95it/s]
```

```
Epoch 55/60 | 250/250 | 0s 2s/step - train_acc: 0.8462 - val_acc: 0.7032  
100%|██████████| 32/32 [00:00<00:00, 3082.28it/s]  
Epoch 56/60 | 250/250 | 0s 2s/step - train_acc: 0.8542 - val_acc: 0.7145  
100%|██████████| 32/32 [00:00<00:00, 3235.57it/s]  
Epoch 57/60 | 250/250 | 0s 2s/step - train_acc: 0.8621 - val_acc: 0.7224  
100%|██████████| 32/32 [00:00<00:00, 3644.55it/s]  
Epoch 58/60 | 250/250 | 0s 2s/step - train_acc: 0.8765 - val_acc: 0.7326  
100%|██████████| 32/32 [00:00<00:00, 3192.16it/s]  
Epoch 59/60 | 250/250 | 0s 2s/step - train_acc: 0.8825 - val_acc: 0.742  
100%|██████████| 32/32 [00:00<00:00, 2998.01it/s]  
Epoch 60/60 | 250/250 | 0s 2s/step - train_acc: 0.9966 - val_acc: 0.794  
100%|██████████| 32/32 [00:00<00:00, 3388.74it/s]
```

## النتائج:




Train\_acc = 0.9966 , val\_acc = 0.794

هذا يعني أنه طبقة الاستخراج الميزات Feature Extraction الذي دربناه لم يعطيني نتائج المطلوبة.

تريد



حتى



من



استفراغه




لم تنجح الخطة كما هو متوقع.

أدركنا هنا أن بنية MobileNet ضعيفة نسبياً في تلبية متطلبات مشروعاتنا، فقمنا بالبحث عن شبكة بديلة. وجدنا أن شبكة CLIP يمكن أن تكون خياراً جيداً، حيث أظهرت نتائج ممتازة في معالجة الصور والنصوص معاً. ولكن، وجدنا أنها تواجه نفس المشكلة التي واجهناها مع النماذج الأخرى: فهي مدربة على صور بحجم 224x224، مما يجعلها غير متوافقة مباشرة مع أبعاد صورنا.

لهذا السبب، لم نقم بتدريبها، لأن بنيتها لا تختلف اختلافاً جوهرياً عن نموذج MobileNet من حيث متطلبات حجم الصورة، وكنا سنتوقع مواجهة نفس المشكلات المتعلقة بتشوه ملامح النص عند تغيير أبعاد الصور.

## • بنية النموذج CLIP:



بعد أن أظهرت النماذج السابقة قصوراً في التعامل مع تعقيدات المخطوطات العربية، بسبب عدم كفاءة بنيتها، دفعنا إلى اللجوء إلى استخدام نموذج آخر أكثر تطوراً وله بنية أعمق وأكثر قدرة على معالجة هذا النوع من البيانات الصعبة فتوصلنا إلى الحل الأمثل وهو استخدام نموذج EfficientNet

## :EfficientNet -2


تُعد EfficientNet عائلة من نماذج الشبكات العصبية الالتفافية (CNN) التي تم تطويرها من قبل باحثي جوجل في عام 2019. تكمن الفكرة الرئيسية وراء هذه النماذج في تحقيق توازن مثالي بين الدقة والكفاءة، مما يجعلها تتفوق على العديد من النماذج السابقة.

يعتمد هذا النموذج على تقنية تعرف باسم "التحجيم المركب (Compound Scaling)"، والتي تتيح زيادة حجم النموذج بشكل موحد عبر ثلاثة أبعاد: العمق (Depth)، والعرض (Width)، ودقة الصورة (Resolution). على عكس الأساليب التقليدية التي تركز على تحجيم بُعد واحد فقط، فإن هذه الطريقة تسمح بتحسين أداء النموذج بشكل كبير دون زيادة غير ضرورية في الموارد الحسابية.

بسبب هذه الخصائص، تُعتبر EfficientNet خياراً قوياً في مهام الرؤية الحاسوبية، وتحديدًا في مشروعنا، حيث توفر دقة عالية في استخلاص الخصائص البصرية من صور المخطوطات مع الحفاظ على كفاءة التدريب.

هذا النهج المبتكر يتيح للنموذج أن ينمو بكفاءة عالية، مما يجعله قادراً على تحقيق أداء فائق (حتى أفضل من النماذج الأكبر والأكثر تعقيداً) مع عدد أقل بكثير من المعلمات وحسابات أقل.

### • بنية شبكة الـ CNN:



بما أننا وجدنا أن الأسلوب الأول غير فعال مع نموذج **MobileNet**، قررنا عدم تكراره مع نموذج **EfficientNet**. لذلك، انتقلنا مباشرة إلى الأسلوب الثاني، وهو إبقاء النموذج كما هو ووضعه ضمن بنية وصف الصور (**Image Captioning**)، ومن ثم بدأنا عملية التدريب حديثاً كانت Epoch = 70, batch\_size = 32, learning\_rate = 1e-4.

- في هذه المرحلة، كانت مجموعة البيانات الحقيقية التي قمنا بتجهيزها قد أصبحت جاهزة. وبما أننا اكتشفنا أن حجمها لم يكن كافياً بمفردها لتدريب النموذج بشكل فعال، قمنا بدمجها مع البيانات الاصطناعية التي قمنا بتوليدها مسبقاً، وذلك لتعزيز عملية التدريب وضمان أن النموذج سيتعلم من كمية كافية من أمثلة.

```
Epoch 0/70 | 250/250 | 0s 2s/step - train_acc: 0.767 - val_acc: 0.822
```

```
100%|██████████| 32/32 [00:00<00:00, 3010.65it/s]
```

```
Epoch 1/70 | 250/250 | 0s 2s/step - train_acc: 0.773 - val_acc: 0.823
```

```
100%|██████████| 32/32 [00:00<00:00, 3234.79it/s]
```

```
Epoch 2/70 | 250/250 | 0s 2s/step - train_acc: 0.795 - val_acc: 0.827
```

```
100%|██████████| 32/32 [00:00<00:00, 3914.31it/s]
```

```
Epoch 3/70 | 250/250 | 0s 2s/step - train_acc: 0.834 - val_acc: 0.833
```

```
100%|██████████| 32/32 [00:00<00:00, 3300.57it/s]
```

```
Epoch 4/70 | 250/250 | 0s 2s/step - train_acc: 0.868 - val_acc: 0.859
```

```
100%|██████████| 32/32 [00:00<00:00, 3364.27it/s]
```

```
Epoch 5/70 | 250/250 | 0s 2s/step - train_acc: 0.869 - val_acc: 0.864
```

```
100%|██████████| 32/32 [00:00<00:00, 3515.67it/s]
```

```
Epoch 6/70 | 250/250 | 0s 2s/step - train_acc: 0.893 - val_acc: 0.882
```

```
100%|██████████| 32/32 [00:00<00:00, 3617.05it/s]
```

Epoch 55/70 | 250/250 | 0s 2s/step - train\_acc: 0.935 - val\_acc: 0.894

100%|██████████| 32/32 [00:00<00:00, 3336.76it/s]

Epoch 56/70 | 250/250 | 0s 2s/step - train\_acc: 0.948 - val\_acc: 0.898

100%|██████████| 32/32 [00:00<00:00, 3385.83it/s]

Epoch 57/70 | 250/250 | 0s 2s/step - train\_acc: 0.949 - val\_acc: 0.928

100%|██████████| 32/32 [00:00<00:00, 3884.40it/s]

Epoch 58/70 | 250/250 | 0s 2s/step - train\_acc: 0.97 - val\_acc: 0.934

100%|██████████| 32/32 [00:00<00:00, 3720.00it/s]


Epoch 59/70 | 250/250 | 0s 2s/step - train\_acc: 0.971 - val\_acc: 0.939

100%|██████████| 32/32 [00:00<00:00, 3795.32it/s]

Epoch 60/70 | 250/250 | 0s 2s/step - train\_acc: 0.996 - val\_acc: 0.96

100%|██████████| 32/32 [00:00<00:00, 3744.39it/s]

## النتائج:



وهي أفضل نتائج توصلنا اليها  
نتائج الـ Attention كانت كالتالي:

أو

أو غيره ولا يعجز ابتداء بختة وهو عسر قاتل والورم العلب يعجز قليلا قليلا ويعقب الورم العار

غيره

أو غيره ولا يعجز ابتداء بختة وهو عسر قاتل والورم العلب يعجز قليلا قليلا ويعقب الورم العار

ولا

أو غيره ولا يعجز ابتداء بختة وهو عسر قاتل والورم العلب يعجز قليلا قليلا ويعقب الورم العار

يحدث

سمي

أو غيره ولا يعجز ابتداء بختة وهو عسر قاتل والورم العلب يعجز قليلا قليلا ويعقب الورم العار

ابتداء

أو غيره ولا يعجز ابتداء بختة وهو عسر قاتل والورم العلب يعجز قليلا قليلا ويعقب الورم العار

بغثة

أو غيره ولا يعجز ابتداء بختة وهو عسر قاتل والورم العلب يعجز قليلا قليلا ويعقب الورم العار

وهو

أو غيره ولا يعجز ابتداء بختة وهو عسر قاتل والورم العلب يعجز قليلا قليلا ويعقب الورم العار

عسر

أو غيره ولا يعجز ابتداء بختة وهو عسر قاتل والورم العلب يعجز قليلا قليلا ويعقب الورم العار

قاتل

أو غيره ولا يجرى ابتداءً بختة وهو عسر قاتل والورم العلب يجرى قليلاً قليلاً ويعقب الورم العار

الورم

أو غيره ولا يجرى ابتداءً بختة وهو عسر قاتل والورم العلب يجرى قليلاً قليلاً ويعقب الورم العار

الصلب

أو غيره ولا يجرى ابتداءً بختة وهو عسر قاتل والورم العلب يجرى قليلاً قليلاً ويعقب الورم العار

يحدث

أو غيره ولا يجرى ابتداءً بختة وهو عسر قاتل والورم العلب يجرى قليلاً قليلاً ويعقب الورم العار

قليلاً

أو غيره ولا يجرى ابتداءً بختة وهو عسر قاتل والورم العلب يجرى قليلاً قليلاً ويعقب الورم العار

ويعقب

أو غيره ولا يجرى ابتداءً بختة وهو عسر قاتل والورم العلب يجرى قليلاً قليلاً ويعقب الورم العار

الورم

أو غيره ولا يجرى ابتداءً بختة وهو عسر قاتل والورم العلب يجرى قليلاً قليلاً ويعقب الورم العار

العار

أو غيره ولا يجرى ابتداءً بختة وهو عسر قاتل والورم العلب يجرى قليلاً قليلاً ويعقب الورم العار

[END]

أو غيره ولا يجرى ابتداءً بختة وهو عسر قاتل والورم العلب يجرى قليلاً قليلاً ويعقب الورم العار

🚩 وهنا قد انتهينا من تدريب شبكة ال CNN

## B. المحولات (Transformers) :

بعد أن تقوم شبكة CNN بمعالجة الصورة واستخلاص الخصائص البصرية منها، ننتقل إلى مرحلة ال-Transformer.

كما وضعنا سابقا من الشكل (4-10) ان المحول (Transformer) يحتوي على عدة طبقات:

### 1. Text Vectorization :

هي أداة مهمة في معالجة اللغة الطبيعية (NLP) ، وظيفتها الأساسية تحويل النصوص (كلمات وجمل) إلى أرقام، حتى تقدر الشبكات العصبية تتعلم منها وتستخدمها في التدريب أو التنبؤ.

هذه الطبقة تقوم بعمل ما يلي:

#### a) بناء قاموس (Vocabulary):

- تجمع الكلمات الموجودة في البيانات.

- تعطي لكل كلمة رقم مميز (ID).

مثال:

- "سلام" → 1

- "كيف" → 2

- "حال" → 3

#### b) تحويل النصوص إلى أرقام:

- الجملة "سلام كيف حالك" تتحول إلى [1, 2, 3].

```
# Use the top 5000 words for a vocabulary.
vocabulary_size = 500000
tokenizer = tf.keras.layers.TextVectorization(
    max_tokens=vocabulary_size,
    standardize=standardize,
    ragged=True)
# Learn the vocabulary from the caption data.
```

```
t = tokenizer(['أحدث سكتة لي مما يحتاج إلى تحويل العلة في الفالج إن في نصفه أحدث فالجا وإن حدث في كله'])
t
```

```
<tf.RaggedTensor [[2, 800, 1597, 31, 133, 230, 11, 7295, 49, 5, 78, 51, 5, 691, 800, 2754,
30, 82, 5, 98, 3]]>
```

## 2. Sequence Embedding:

وظيفتها الرئيسية هي تحويل الأرقام (التي تمثل الكلمات) إلى تمثيلات رقمية غنية بالمعلومات، مع إضافة معلومات حول موقع كل كلمة في الجملة. وهذا مهم جداً لأن الـ **Transformer** يعالج الكلمات بشكل متوازٍ، وليس بشكل تسلسلي، مما يجعله بحاجة إلى طريقة لفهم ترتيب الكلمات.

تتكون هذه الطبقة من جزأين:

### (a) تضمين الكلمات Token Embedding:

- هذه الطبقة تحول كل رقم (الذي يمثل كلمة) إلى متجه (Vector) من الأرقام العائمة. هذا المتجه يُسمى "تضمين الكلمة" (Word Embedding).
- الفكرة هي أن الكلمات التي تحمل معاني متشابهة أو تظهر في سياقات مماثلة سيكون لها متجهات متقاربة في الفضاء الرقمي، مما يساعد النموذج على فهم العلاقات بين الكلمات.

### (b) تضمين الموقع Position Embedding:

- وظيفة هذه الطبقة هي إعطاء معلومات حول موقع كل كلمة في السطر. فهي تُنشئ متجهاً لكل موقع (الكلمة الأولى، الثانية، الثالثة، وهكذا).
- يُعد هذا التضمين ضرورياً لأن الـ **Transformer** لا يفهم الترتيب بشكل تلقائي، وبالتالي فإن إضافة تضمين الموقع تساعد النموذج على معرفة مكان كل كلمة في التسلسل.
- أخيراً، يتم جمع (Add) كلا المتجهين معاً. الناتج هو متجه جديد يجمع بين معنى الكلمة وموقعها، ليتم تغذيته في طبقات الـ **Transformer** اللاحقة.

```
self.seq_embedding = SeqEmbedding(
    vocab_size=tokenizer.vocabulary_size(),
    depth=units,
    max_length=max_length)
```

### 3. طبقات المفكك Decoder Layers:

تُعد بنية الـ **Decoder (المفكك)** الجزء المسؤول عن توليد النص الفعلي.

يعمل الـ **Decoder** على توليد النص كلمة بكلمة، حيث يستخدم ما يعرف بـ "آلية الانتباه (**Attention Mechanism**)" للتركيز على الأجزاء الأكثر صلة في الصورة عند توليد كل كلمة. فمثلاً، عندما يصل إلى مرحلة توليد كلمة "خط"، فإنه يوجه انتباهه إلى منطقة في الصورة تحتوي على خطوط، مما يضمن أن يكون النص الذي يولده متوافقاً مع المحتوى البصري.

يتكون الـ **Decoder** من عدة طبقات متكررة وهي `num_layers = 8`

```
self.decoder_layers = [  
    DecoderLayer(units, num_heads=num_heads, dropout_rate=dropout_rate)  
    for n in range(num_layers)]
```

### 4. طبقات الخرج Token Output:

تُعد طبقة **TokenOutput** هي الطبقة النهائية في بنية المفكك (Decoder)، وتتمثل وظيفتها في تحويل المخرجات النهائية للنموذج إلى كلمات قابلة للقراءة.

بعد أن تقوم طبقات الـ **DecoderLayer** بمعالجة البيانات وتحديد الاحتمالات لكافة الكلمات، يتم تمرير هذه النتائج إلى طبقة **TokenOutput**. وظيفة هذه الطبقة هي تحويل هذه الاحتمالات إلى كلمة فعلية.

```
output_layer = TokenOutput(tokenizer, banned_tokens=('', '[UNK]', '[START]'))  
# This might run a little faster if the dataset didn't also have to load the image data.  
output_layer.adapt(train_ds.map(lambda inputs, labels: labels))
```

وبالنهاية كان النموذج النهائي. 🏁

```
model = Captioner(tokenizer, feature_extractor=efficientnet, output_layer=output_layer,  
                  units=256, dropout_rate=0.3, num_layers=8, num_heads=2)
```

### الخلاصة:

استخدمنا 8 طبقات Decoder حيث أنه كان عدد الـ head-attention = 2 وكان عدد الـ units = 256

وكان dropout\_rate = 0.3

ثم قمنا بالتدريب حيث أنه كانت :

خوارزمية التعليم Adam , learning\_rate = 1e-4 , batch\_size = 32 , epoch = 70

```
model.compile(optimizer=tf.keras.optimizers.Adam(learning_rate=1e-4),  
              loss=masked_loss,  
              metrics=[masked_acc])
```

```
history = model.fit(train_ds, validation_data=test_ds, epochs=60, steps_per_epoch=steps_per_epoch,  
                    validation_steps=validation_steps, callbacks=callbacks)
```

Epoch 0/70 | 250/250 | 0s 2s/step - train\_acc: 0.685 - val\_acc: 0.596

100%|██████████| 32/32 [00:00<00:00, 2989.79it/s]

Epoch 1/70 | 250/250 | 0s 2s/step - train\_acc: 0.692 - val\_acc: 0.603

100%|██████████| 32/32 [00:00<00:00, 3668.45it/s]

Epoch 2/70 | 250/250 | 0s 2s/step - train\_acc: 0.71 - val\_acc: 0.607

100%|██████████| 32/32 [00:00<00:00, 4014.77it/s]

Epoch 3/70 | 250/250 | 0s 2s/step - train\_acc: 0.71 - val\_acc: 0.622

100%|██████████| 32/32 [00:00<00:00, 3827.90it/s]

Epoch 4/70 | 250/250 | 0s 2s/step - train\_acc: 0.719 - val\_acc: 0.622

100%|██████████| 32/32 [00:00<00:00, 3955.49it/s]

Epoch 5/70 | 250/250 | 0s 2s/step - train\_acc: 0.742 - val\_acc: 0.632

100%|██████████| 32/32 [00:00<00:00, 3594.86it/s]

Epoch 6/70 | 250/250 | 0s 2s/step - train\_acc: 0.759 - val\_acc: 0.638

100%|██████████| 32/32 [00:00<00:00, 2528.83it/s]

100%|██████████| 32/32 [00:00<00:00, 3554.49it/s]

Epoch 56/70 | 250/250 | 0s 2s/step - train\_acc: 0.791 - val\_acc: 0.683

100%|██████████| 32/32 [00:00<00:00, 2286.54it/s]

Epoch 57/70 | 250/250 | 0s 2s/step - train\_acc: 0.794 - val\_acc: 0.686

100%|██████████| 32/32 [00:00<00:00, 3023.26it/s]

Epoch 58/70 | 250/250 | 0s 2s/step - train\_acc: 0.843 - val\_acc: 0.688

100%|██████████| 32/32 [00:00<00:00, 2477.26it/s]


Epoch 59/70 | 250/250 | 0s 2s/step - train\_acc: 0.852 - val\_acc: 0.689

100%|██████████| 32/32 [00:00<00:00, 3368.67it/s]

Epoch 60/70 | 250/250 | 0s 2s/step - train\_acc: 0.854 - val\_acc: 0.729

100%|██████████| 32/32 [00:00<00:00, 3373.66it/s]

## النتائج:




Train\_acc = 0.854 , val\_acc = 0.729

🚦 نلاحظ أن النتائج الأولية لم تكن مقبولة، ويعود السبب في ذلك إلى أننا استخدمنا مجموعة البيانات الحقيقية التي قمنا بتجهيزها يدوياً وحدها، والتي كانت غير كافية لتدريب النموذج بشكل فعال. ولهذا السبب، قمنا بدمجها مع مجموعة البيانات الاصطناعية التي أنشأناها، ثم طبقنا عليها تقنية توسيع البيانات (Data Augmentation) ، مما ساعد في تحسين أداء النموذج بشكل كبير.

ثم اعدنا التدريب مع تغيير معدل التعلم لـ  $\text{learning\_rate} = 1e-7$

### النتائج:



Train\_acc = 0.99 , val\_acc = 0.968

🚦 وهنا نرى أن الشبكة قد تدربت على أمكانية تحويل الصورة المخطوطة القديمة على نص (إعطاء وصف لصورة).

## References:

- 1) <https://journalofbigdata.springeropen.com/articles/10.1186/s40537-019-0197-0>
- 2) <https://arxiv.org/abs/1706.03762>
- 3) <https://arxiv.org/abs/1905.11946>
- 4) <https://arxiv.org/abs/1704.04861>
- 5) <https://towardsdatascience.com/image-captioning-using-attention-based-transformer-models-d72b226e6d5e>
- 6) <https://machinelearningmastery.com/data-augmentation-for-image-recognition/>
- 7) <https://www.youtube.com/watch?v=J8N7K6D4g5E>

## Summary

Preserving written heritage and restoring ancient manuscripts are among the most significant challenges in the age of digital transformation. These manuscripts contain valuable historical and intellectual treasures, but their age and vulnerability to damage make them difficult to access directly. Therefore, this project aims to develop a computer system that converts images of ancient manuscripts into digital texts that can be processed, stored, and searched.

Our methodology relies on using image processing techniques to extract text from manuscripts, then applying Optical Character Recognition (OCR) algorithms adapted to the nature of ancient Arabic script, with improvements using Artificial Intelligence and deep learning techniques to increase conversion accuracy. This project contributes to preserving human heritage and making it accessible to researchers and those interested in a way that is easy to access and process, thereby promoting the sustainability of historical knowledge and preventing its loss over time.

### Key words:

Restoration of Manuscripts - Digital Transformation - Optical Character Recognition - Heritage Preservation - Electronic Archiving.